

COURS DE STATISTIQUE DESCRIPTIVE

Semestre 1

Dr Brou Kouakou G.



Sommaire

Chapitre 1 • Introduction à la statistique descriptive	1
Chapitre 2 • Les caractéristiques de tendance centrale	35
Chapitre 3 • Les caractéristiques de dispersion	63
Chapitre 4 • Les caractéristiques de forme et de concentration	83
Chapitre 5 • Les séries bivariées.....	107
Chapitre 6 • La régression	145

Introduction à la statistique descriptive

1. Terminologie.....	2
2. Présentation des données.....	8
3. Représentations graphiques des séries à une variable	10

Problèmes et exercices

1. De la série brute à la présentation des statistiques ..	18
2. Représentations graphiques simples	22
3. L'histogramme	25
4. Discretisation des données	26
5. Les polygones	29

Les méthodes de la statistique descriptive (statistique déductive) permettent de mener des études à partir de données exhaustives, c'est-à-dire concernant tous les individus de la population concernée par l'étude. Comme le rappelle André Vessereau (voir bibliographie), l'idée première et toujours fondamentale de la statistique descriptive est celle de dénombrement.

Quand les données ne concernent qu'un échantillon de la population, comme dans le cas des sondages, on a recours à la statistique inférentielle (statistique inductive), qui utilise la théorie des probabilités.

Globalement, la statistique reste très liée à la science du hasard, puisque les recensements nous fournissent des fréquences d'apparition auxquelles on fait jouer le même rôle qu'à la probabilité. Déjà, les manuscrits de Gottfried Leibniz, rédigés au début des années 1680, se situaient, à partir des travaux de John Graunt, dans la perspective d'une « synthèse entre science de la population et calcul des probabilités ».

Ce premier chapitre présente les principales clefs de lecture de la statistique. La terminologie usuelle y est exposée, ainsi que la forme et le contenu des tableaux de données.

Deux annexes, proposées en fin de chapitre, sont consacrées à la prise en main d'Excel (annexe 1.1), ou de tout autre tableur équivalent, et d'une calculatrice graphique, Texas Instrument (annexe 1.2), ou de toute autre calculatrice approchante. L'utilisation de ces outils facilitera la compréhension et la résolution de tous les exemples numériques des parties théoriques et des problèmes et exercices qui suivent.

1 Terminologie

Comme toute science, la statistique a son vocabulaire, qu'il est primordial de définir de façon rigoureuse afin d'indiquer le groupe sur lequel porte l'étude, les caractères ou variables relevés sur chacun des individus et les différents types de caractères.

1.1 LA POPULATION

Le terme de population statistique est antérieur à la démographie et s'appliquait à l'origine à des catégories d'humains. Les populations n'étaient en effet pas pensées en bloc, leurs membres n'étant pas considérés comme égaux. Par exemple, on comptait les hommes en état de porter des armes, les individus soumis à l'impôt, etc. La démographie est venue plus tard, avec l'idée d'égalité des individus, qui a mené à la notion de recensement.

En statistique, le terme de population est plus général et peut désigner des humains, mais aussi des objets, des villes, des pays, des entreprises, des logements, etc., l'essentiel étant, comme pour la définition d'un ensemble en mathématiques, que l'on puisse dire clairement de tout élément qu'il appartient ou n'appartient pas à la population.

Les villes européennes de plus de 100 000 habitants, les voitures immatriculées en France, les départements français d'outre-mer sont autant d'exemples de population.

Définition

La **population statistique** est l'ensemble des éléments sur lesquels porte l'étude. Les éléments de la population sont appelés **individus statistiques** ou unités statistiques. La population constitue l'univers de référence de l'étude. Si la population comporte N individus, on notera $\Omega = \{\omega_1 ; \omega_2 ; \dots ; \omega_N\}$ les N individus qui la composent. Un **échantillon** de taille n est un sous-ensemble formé de n individus de la population ($n \leq N$).

La notion d'échantillon est fondamentale, car, en règle générale, la population entière n'est pas disponible ou observable. Dans ce cas, seul un échantillon est étudié et les résultats obtenus sont extrapolés à la population (voir P. Roger, chapitre 5). Par exemple, lorsqu'un magazine souhaite connaître la personnalité préférée des Français, il interroge seulement un échantillon de Français, généralement 1 000 individus, et non toute la population résidant en France métropolitaine, soit plus de 60 millions d'individus.

1.2 NOTION DE CARACTÈRE OU VARIABLE STATISTIQUE

Chaque individu d'une population peut être décrit relativement à un ou plusieurs caractères ou variables statistiques.

Définition

Une **variable statistique**, ou **caractère statistique**, est une application définie sur une population statistique et à valeurs dans un ensemble M , appelé ensemble des modalités. Les **modalités** correspondent aux valeurs possibles de la variable statistique. Une variable statistique définit une partition sur une population, chaque individu appartenant à une et une seule modalité.

Si le nombre de modalités est noté r , l'ensemble des modalités de la variable X sera noté : $M = \{x_1 ; x_2 ; \dots ; x_r\}$.

Exemple 1.1

Une population statistique

Considérons les données suivantes concernant le nombre de femmes et d'hommes dans la population résidant en France métropolitaine en 2006 (en milliers) :

Femmes	Hommes
31 444	29 722

Source : Insee, recensement de la population, 2007 (champ : France métropolitaine)

La population étudiée est la population résidant en France métropolitaine recensée en 2006 et la variable étudiée est le sexe. Cette variable peut prendre deux valeurs possibles appelées modalités : féminin ou masculin. Ces modalités sont en général numérotées : si la variable étudiée, ici le sexe, est notée X , les deux modalités seront respectivement notées x_1 (pour féminin) et x_2 (pour masculin).

Une des premières opérations de la statistique consiste à recenser le nombre et/ou le pourcentage d'individus qui présentent une modalité déterminée d'une variable. C'est ainsi qu'à chaque modalité est associé un effectif et/ou une fréquence.

Définitions

L'**effectif** (aussi appelé fréquence absolue) de la modalité x_i est noté n_i et désigne le nombre d'individus de la population présentant la modalité x_i . L'effectif total de la population n est alors : $n = n_1 + n_2 + \dots + n_r$, soit $n = \sum_{i=1}^r n_i$ (la somme des n_i pour i variant de 1 à r , et la lettre grecque sigma, Σ , désignant la somme).

La **fréquence** (par défaut fréquence relative) de la modalité x_i est notée f_i et est définie par : $f_i = n_i / N$; la fréquence exprime la proportion d'individus présentant une modalité donnée. Elle peut s'exprimer sous la forme d'un nombre décimal (en général avec une précision de quatre chiffres après la virgule) ou sous la forme d'un pourcentage.

Propriété

Soit X une variable à r modalités :

$$0 \leq f_i \leq 1$$

$$\sum_{i=1}^r f_i = 1 \text{ (ou, en pourcentage : } \sum_{i=1}^r f_i = 100 \text{)}$$

Exemple 1.2

Effectifs et fréquences

Reprenons l'exemple précédent sur le sexe des individus de la population résidant en France métropolitaine. Les effectifs respectifs de ces modalités sont notés $n_1 = 31\,444$ et $n_2 = 29\,722$, avec $n = n_1 + n_2 = 61\,166$ milliers, effectif total de la population.

Les fréquences sont telles que : $f_1 = n_1 / n = 31\,444 / 61\,166 = 0,5141$ et $f_2 = n_2 / N = 29\,722 / 61\,166 = 0,4859$, soit 51,41 % de femmes et 48,59 % d'hommes.

L'exemple 1.1 a mis en évidence une des deux natures des variables statistiques : la variable qualitative. Le sexe est une variable qualitative, car ses modalités ne sont pas des nombres. Une variable quantitative est une variable dont les modalités sont numériques. Le poids d'un individu, l'âge, le nombre d'enfants par ménage, le salaire constituent des exemples de variables quantitatives.

1.3 LES VARIABLES QUALITATIVES

Définition

Une variable statistique est dite de nature **qualitative** si ses modalités ne sont pas mesurables. Les modalités d'une variable qualitative sont les différentes catégories d'une nomenclature. Ces catégories doivent être exhaustives (chaque individu est affecté à une modalité) et incompatibles (un individu ne peut être affecté à plusieurs modalités) de façon à créer une partition.

Le sexe, la profession, l'état matrimonial sont quelques exemples de variables qualitatives. Pour ses enquêtes auprès des ménages, l'Insee utilise la nomenclature des Professions et catégories socioprofessionnelles (PCS-2003).

Les modalités d'une variable qualitative peuvent être classées sur deux types d'échelle : nominale ou ordinale. À ces deux types d'échelle correspondent deux types de variables qualitatives.

Variables qualitatives nominales

Les variables qualitatives nominales ne se mesurent pas. Cependant, leurs modalités peuvent être codées. L'ordre et l'origine de la codification sont arbitraires, cette codification pouvant être numérique, alphabétique ou alphanumérique. Les individus d'une même catégorie sont réputés « équivalents » pour la variable étudiée.

Définition

Une variable statistique qualitative est dite définie sur une échelle **nominale** si ses catégories ne sont pas naturellement ordonnées.

Exemple 1.3

Codage d'une variable qualitative nominale

Le tableau suivant indique les différentes catégories de la variable nominale Professions et catégories socioprofessionnelles (CSP) :

Code	Catégorie
1	Agriculteurs exploitants
2	Artisans, commerçants et chefs d'entreprise
3	Cadres et professions intellectuelles supérieures
4	Professions intermédiaires
5	Employés
6	Ouvriers
7	Retraités
8	Autres personnes sans activité professionnelle

Source : Insee, PCS-2003 (niveau 1 de la nomenclature)

Dans cet exemple, il n'y a pas d'ordre naturel entre les huit catégories, ou modalités, qui sont de simples étiquettes ; la variable qualitative « CSP » est définie sur une échelle nominale.

Variables qualitatives ordinales

Une échelle ordinale suppose l'existence d'une relation d'ordre total entre les catégories, c'est-à-dire que l'on peut opérer un classement de l'ensemble des catégories, de la plus petite à la plus grande (ou, inversement, de la plus grande à la plus petite).

Contrairement à ce qui se passe avec une échelle nominale, les expressions telles que « plus grand que », « précède », « se place après », etc. prennent un sens dans une échelle ordinale.

La codification peut être numérique, alphabétique ou alphanumérique, en association avec un sens de lecture. En cas de codage numérique, les opérations mathématiques sont dénuées de sens et l'écart entre les valeurs ne revêt aucune signification.

Définition

Une variable statistique qualitative est dite définie sur une échelle **ordinaire** si l'ensemble de ses catégories peut être doté d'une relation d'ordre.

1.4 LES VARIABLES QUANTITATIVES

Toute variable qui n'est pas qualitative ne peut être que quantitative. Les différentes modalités d'une variable quantitative constituent l'ensemble des valeurs numériques que peut prendre la variable.

Définition

Une variable statistique est dite de nature **quantitative** si ses modalités sont mesurables. Les modalités d'une variable quantitative sont des nombres liés à l'unité choisie, qui doit toujours être précisée.

Il existe deux types de variables quantitatives : les variables discrètes et les variables continues.

Ces variables ont en commun des modalités clairement ordonnées, pour lesquelles l'écart entre les valeurs possède une signification, et sur lesquelles il est possible de réaliser des opérations mathématiques telles que des calculs de moyennes, etc. Néanmoins, elles ont des propriétés et des traitements spécifiques qui nécessitent une étude séparée.

Variables quantitatives discrètes

Lorsque les modalités sont des valeurs numériques isolées, comme le nombre d'enfants par ménage, on parle de variable discrète¹.

Définition

Une variable statistique quantitative est dite **discrète** si l'ensemble de ses modalités est un ensemble fini ou dénombrable. Ainsi, l'ensemble des modalités peut être donné sous la forme d'une liste de nombres, $M = \{x_1 ; x_2 ; \dots ; x_i ; \dots\}$, finie ou infinie.

Le plus souvent, les modalités appartiennent à l'ensemble N des entiers naturels ($N = \{0 ; 1 ; 2 ; \dots\}$). Cependant, une variable discrète peut prendre des valeurs non entières.

Variables quantitatives continues

Lorsque la variable, par exemple la taille d'un individu, peut prendre toutes les valeurs d'un intervalle, ces valeurs peuvent alors être regroupées en classes, et on parle dans ce cas de variable continue.

Définitions

Une variable statistique quantitative est dite **continue** si l'ensemble de ses modalités n'est pas dénombrable. Ainsi, une variable continue peut prendre toutes les valeurs d'un intervalle.

Pour étudier une variable statistique continue, on définit des classes ou intervalles de valeurs possibles. On peut ainsi **discrétiser** une variable continue (voir section 2.1). Les classes retenues constituent les modalités de la variable.

On appelle **amplitude de la classe** $[a_i ; b_i[$ le réel noté A_i représentant la longueur de l'intervalle et défini par : $A_i = b_i - a_i$. a_i et b_i sont respectivement les bornes inférieure et supérieure de la classe n_i .

Le **centre de classe** de la classe $[a_i ; b_i[$ est le réel noté x_i représentant le milieu de l'intervalle et donné par : $x_i = (a_i + b_i) / 2$; c'est la moyenne arithmétique des bornes de la classe.

1. Du latin *discretus*, qui signifie « séparé » ; dans un ensemble discret, on peut séparer les éléments.

Le centre de classe est appelé à jouer un grand rôle dans les calculs, car le regroupement en classes constitue une perte d'information importante ; nous prendrons l'hypothèse de répartition uniforme à l'intérieur d'une classe, c'est-à-dire de concentration au centre des classes (voir chapitre 2).

Exemple 1.4

Calculs d'amplitudes et centres de classes

Le tableau suivant indique la structure par âges de la population féminine en France métropolitaine :

Âge	f_i (%)
Moins de 15 ans	17,5
15-24 ans	12,3
25-34 ans	12,7
35-44 ans	14,0
45-54 ans	13,6
55-64 ans	11,1
65-74 ans	8,6
75 ans ou +	9,1

Source : Insee, bilan démographique, 2006

Les modalités sont des intervalles qui, par convention, sont – à part pour la dernière classe – fermés à gauche et ouverts à droite. Ainsi, la première classe se note aussi : $[0 ; 15[$, la deuxième $[15 ; 25[$, etc.

Les classes ne sont pas de même amplitude, la première classe ayant une amplitude de 15 ans et les suivantes de 10 ans. Pour la dernière classe, dont l'amplitude n'est pas définie explicitement, la convention suivante est adoptée : en l'absence d'information, il lui est attribué l'amplitude de la classe précédente, $[65 ; 75[$, donc 10 ans, et elle est donc écrite : $[75 ; 85[$.

Le centre de la première classe est : $x_1 = (a_1 + b_1) / 2 = (0 + 15) / 2 = 7,5$ ans.

Cette distinction entre variable discrète et variable continue est parfois arbitraire, toute mesure étant discrète du fait de la précision limitée des instruments de mesure ou des arrondis. Cependant, la taille d'un individu, par exemple, est une variable continue du fait que, indépendamment de la mesure, toute valeur de l'intervalle $[140 ; 150[$ peut représenter en centimètres la taille d'un individu. De même, il arrive qu'une variable discrète, comme le nombre d'habitants d'un pays, qui peut prendre un grand nombre de valeurs dans un intervalle soit considérée comme une variable continue.

En conclusion, toute étude de variable statistique devra être précédée d'une identification claire de la population, du caractère étudié et de sa nature, à savoir qualitatif ou quantitatif et, dans le cas quantitatif, discret ou continu.

2 Présentation des données

Les données statistiques sont issues de données brutes présentées sous forme de tableaux statistiques dans lesquels sont indiqués les effectifs et/ou les fréquences.

2.1 DISTRIBUTION DES EFFECTIFS OU DES FRÉQUENCES

Les tableaux statistiques contenant les effectifs et/ou les fréquences sont une première exploitation des données brutes.

Des données brutes au tableau statistique

Il est primordial de définir la population et de préciser avec rigueur la ou les variables relevées sur chacun des individus de la population ou de l'échantillon la représentant. Ensuite, quand les observations ont été recueillies, le premier travail consiste à les présenter, aussi clairement que possible, sous forme de tableau statistique. Ce tableau révèle la distribution statistique en présentant les couples de type $(x_i ; n_i)$, où les x_i sont les modalités et les n_i leurs effectifs respectifs, i entier variant de 1 à r , si r désigne le nombre de modalités du caractère. Il est également possible de présenter la distribution des fréquences, c'est-à-dire les couples de type $(x_i ; f_i)$.

Définitions

On appelle **données brutes** ou tableau élémentaire le tableau relevant pour chaque unité statistique la modalité de la variable étudiée.

Le **tri à plat** est la transformation qui permet de passer du tableau des données brutes au tableau de la distribution statistique présentant les modalités et les effectifs, les modalités étant classées par ordre croissant.

Discrétisation

Dans le cas d'une variable statistique quantitative continue, il est nécessaire de définir des classes pour pouvoir proposer un tri à plat.

Définition

On appelle **discrétisation** le découpage en classes d'une série statistique quantitative.

Ce découpage en classes pose de nombreuses questions : choix des amplitudes, amplitudes constantes ou variables, nombre de classes, etc. Nous ne rentrerons pas ici dans le détail de ces opérations (voir l'exercice 4 de ce chapitre).

2.2 VARIABLES QUANTITATIVES : DISTRIBUTION DES EFFECTIFS ET DES FRÉQUENCES CUMULÉS

Cette section concerne les variables quantitatives pour lesquelles le tableau statistique est réalisé, les modalités étant ordonnées dans l'ordre croissant. Les notions que nous allons définir sont liées à la notion de fonction de répartition, fondamentale en probabilité pour les variables aléatoires continues et sur laquelle nous reviendrons dans la section 3.3.

Reprenons l'exemple 1.4 et proposons de répondre à la question suivante : quelle proportion de la population féminine en France métropolitaine a moins de 35 ans ?

Nous pouvons affirmer que 42,5 % de la population féminine en France métropolitaine a moins de 35 ans, soit 17,5 % + 12,3 % + 12,7 %. Pour obtenir ce résultat, nous avons cumulé les fréquences des modalités inférieures ou égales à 34 ans.

Définitions

Effectifs cumulés croissants sur variable discrète : Si X désigne une variable quantitative discrète, on appelle effectif cumulé croissant, noté $n_{i,cc}$, le nombre d'individus statistiques pour lesquels X est inférieur ou égal à x_i .

On a : $n_{1,cc} = n_1$ et $n_{i,cc} = n_1 + n_2 + \dots + n_i = \sum_{k=1}^i n_k$.

Si la série possède r modalités, x_r désignant alors la plus grande valeur de X , on a : $n_{r,cc} = n_1 + n_2 + \dots + n_r = \sum_{k=1}^r n_k = n$, où n désigne l'effectif total de la série.

Fréquences cumulées croissantes sur variable discrète : Avec les mêmes hypothèses, on définit la fréquence cumulée croissante, notée $f_{i,cc}$, représentant la proportion d'individus statistiques pour lesquels X est inférieur ou égal à x_i .

On a : $f_{1,cc} = f_1$ et $f_{i,cc} = f_1 + f_2 + \dots + f_i = \sum_{k=1}^i f_k$, ou encore $f_{i,cc} = \frac{n_{i,cc}}{n}$.

Si la série possède r modalités, x_r désignant alors la plus grande valeur de X , on a : $f_{r,cc} = f_1 + f_2 + \dots + f_r = \sum_{k=1}^r f_k = 1$ (ou 100 si les fréquences sont exprimées en pourcentage).

Dans le cas d'une **variable quantitative continue**, les données sont groupées en classes $[a_i ; b_i[$, et on définit, de même que pour une variable discrète, $n_{i,cc}$ le nombre d'individus statistiques pour lesquels X est inférieur ou égal à b_i , et $f_{i,cc}$ la proportion d'individus statistiques pour lesquels X est inférieur ou égal à b_i .

Il est également possible de cumuler les effectifs et les fréquences dans le sens décroissant.

Définitions

Effectifs cumulés décroissants sur variable discrète : Si X désigne une variable quantitative discrète, on appelle effectif cumulé décroissant, noté $n_{i,cd}$, le nombre d'individus statistiques pour lesquels X est supérieur ou égal à x_i .

(Certains auteurs adoptent une convention différente : le nombre d'individus statistiques pour lesquels X est strictement supérieur à x_i).

On a : $n_{1,cd} = n$; $n_{i,cd} = n_i + n_{i+1} + \dots + n_r = \sum_{k=i}^r n_k$, r désignant le nombre de modalités, et $n_{r,cd} = n_r$.

Fréquences cumulées décroissantes sur variable discrète : Avec les mêmes hypothèses, on définit la fréquence cumulée décroissante, notée $f_{i,cd}$, représentant la proportion d'individus statistiques pour lesquels X est supérieur ou égal à x_i .

On a : $f_{1,cd} = 1$; $f_{i,cd} = f_i + f_{i+1} + \dots + f_r = \sum_{k=i}^r f_k$, et $f_{r,cd} = f_r$, ou encore $f_{i,cd} = \frac{n_{i,cd}}{n}$.

Dans le cas d'une **variable quantitative continue**, les données sont groupées en classes $[a_i ; b_i[$, et on définit, de même que pour une variable discrète, $n_{i,cd}$ le nombre d'individus statistiques pour lesquels X est supérieur ou égal à a_i , et $f_{i,cd}$ la proportion d'individus statistiques pour lesquels X est supérieur ou égal à a_i .

Exemple 1.5

Calculs d'effectifs et fréquences cumulés croissants et décroissants

Le tableau suivant recense les enfants de moins de 6 ans en France métropolitaine :

Année	Moins de 3 ans	De 3 à 5 ans
2006	2 294 846	2 317 874

Source : Insee, bilan démographique, 2006

Les effectifs cumulés croissants ($n_{i,cc}$), décroissants ($n_{i,cd}$), et les fréquences cumulées croissantes ($f_{i,cc}$), décroissantes ($f_{i,cd}$), correspondants sont les suivants :

Âge	n_i	$n_{i,cc}$	$n_{i,cd}$	$f_{i,cc}$	f_i	$f_{i,cd}$
[0 ; 3[	2 294 846	2 294 846	4 612 720	0,4975	0,4975	1
[3 ; 6[	2 317 874	4 612 720	2 317 874	1	0,5025	0,5025
Total	4 612 720				1,0000	

3 Représentations graphiques des séries à une variable

L'apparition des graphiques statistiques, liée à l'utilisation des coordonnées, doit essentiellement son origine au philosophe et mathématicien René Descartes (1596-1650). Ces graphiques constituent une synthèse visuelle indispensable de l'information contenue dans le tableau statistique.

Les graphiques utilisés dépendent de la nature de la variable. Nous utiliserons, pour représenter les distributions d'effectifs (ou de fréquences), les diagrammes circulaires (ou secteurs), les diagrammes en tuyaux d'orgue, les diagrammes en bâtons, les histogrammes et le polygone des effectifs. Pour les distributions cumulées, nous utiliserons les polygones des effectifs (ou des fréquences) cumulés croissants et décroissants.

3.1 GRAPHIQUES POUR VARIABLES QUALITATIVES

Les variables qualitatives – nominales ou ordinales – peuvent être représentées au choix à l'aide d'un diagramme circulaire ou à l'aide d'un diagramme en tuyaux d'orgue.

Diagramme circulaire

Le diagramme circulaire, également appelé « camembert », permet une représentation de la distribution d'une variable dans un cercle qui représente 100 % des modalités (voir figure 1.1).

Définition

Un **diagramme circulaire** est un graphique constitué d'un cercle divisé en secteurs dont les angles au centre sont proportionnels aux effectifs (ou aux fréquences). De fait, les aires des secteurs sont proportionnelles aux effectifs. L'angle α_i d'une modalité d'effectif n_i est donné en

degrés par : $\alpha_i = \frac{n_i}{n} \times 360 = f_i \times 360$.


Il est également possible d'utiliser un graphique semi-circulaire formé d'un demi-cercle (180°).

Diagramme en tuyaux d'orgue (en barres)

Le diagramme en tuyaux d'orgue est une représentation de la distribution d'une variable selon des rectangles horizontaux ou verticaux ayant tous une même base, de largeur arbitraire (voir figure 1.2).

Figure 1.1

Diagramme circulaire :
proportion (en pourcentage) de bacheliers et non-bacheliers dans une génération en France métropolitaine et DOM, 2005.




Définition

Un **diagramme en tuyaux d'orgue** est un graphique qui à chaque modalité d'une variable qualitative associe un rectangle de base constante dont la hauteur est proportionnelle à l'effectif (ou à la fréquence). De fait, les aires des secteurs sont proportionnelles aux effectifs. Les rectangles sont en général disjoints, verticaux ou horizontaux.

Figure 1.2

Diagramme en tuyaux d'orgue :
proportion (en pourcentage) de bacheliers et non-bacheliers dans une génération en France métropolitaine et DOM, 2005.



3.2 GRAPHIQUES POUR VARIABLES QUANTITATIVES

La représentation graphique d'une variable quantitative dépend de sa nature : discrète ou continue.

Variables discrètes : diagramme en bâtons


La distribution d'une variable quantitative discrète peut être représentée par un diagramme en bâtons (voir figure 1.3).

Définition

On appelle **diagramme en bâtons** un graphique qui à chaque modalité d'une variable quantitative discrète associe un segment (bâton) dont la hauteur est proportionnelle à l'effectif (ou à la fréquence).

Figure 1.3

Diagramme en bâtons et polygone des effectifs : nombre de personnes par ménage, France, 1999.



Variables continues : histogramme

En 2005 Monaco avait 32 543 habitants et le Japon 127 417 244 (source : Institut national d'études démographiques). Bien sûr, les démographes diront que ces renseignements sont très largement insuffisants pour comparer la démographie des deux pays : il faut au minimum s'intéresser aux superficies de ces deux pays et calculer pour chacun d'entre eux la densité de population, c'est-à-dire le nombre d'habitants au kilomètre carré. Avec une superficie de 2,02 km² pour Monaco et de 378 000 km² pour le Japon, les densités sont respectivement $d_1 = 32\,543 / 2,02 = 16\,110,40$ h/km² pour Monaco et $d_2 = 127\,417\,244 / 378\,000 = 337$ h/km² pour le Japon. Autrement dit, alors que la population de Monaco est la moins importante en taille, sa densité de population est plus importante que celle du Japon.

Cette notion de densité est essentielle pour les variables continues : il est absurde de comparer ou de représenter côte à côte des classes qui n'ont pas la même amplitude sans faire intervenir la densité. Ce principe est omniprésent lors de la réalisation d'un histogramme.

Définitions

Un **histogramme** est un diagramme composé de rectangles contigus dont les aires sont proportionnelles aux effectifs (ou aux fréquences) et dont les bases sont déterminées par les intervalles de classes.

Dans le cas d'une variable quantitative continue, on définit la **densité** d'effectif d_i d'une classe d'effectif n_i et d'amplitude a_i par : $d_i = n_i / a_i$ (ou, dans le cas des fréquences, f_i / a_i).

Lors de la réalisation d'un histogramme, il est indispensable de distinguer deux cas.

1. Si les amplitudes de classes sont égales, la hauteur des rectangles correspondra aux effectifs (ou aux fréquences) des classes.
2. Si les amplitudes sont différentes, afin de constituer l'histogramme, il est nécessaire de :
 - calculer, pour chaque classe, l'amplitude a_i ;
 - calculer la densité $d_i = n_i / a_i$ pour un histogramme des effectifs, et $d_i = f_i / a_i$ pour un histogramme des fréquences ;
 - affecter à chaque rectangle une hauteur proportionnelle à la densité d_i de la classe correspondante.

Soit $\min(a_i)$ l'amplitude minimale de classe, la hauteur est alors appelée « effectif corrigé » et notée $n_{ic} = d_i \times \min(a_i)$; cette convention revient à adopter $\min(a_i)$ comme unité d'amplitude de classe. Les classes ayant pour amplitudes $\min(a_i)$ sont alors représentées par des rectangles dont la hauteur est l'effectif. De même, il est possible de retenir comme hauteur la fréquence corrigée $f_{ic} = d_i \times \min(a_i)$, avec $d_i = f_i / a_i$ dans le cas d'un histogramme des fréquences. L'utilisation de $\min(a_i)$ est une convention facultative ; un histogramme est correct dès lors que les effectifs (ou les fréquences) corrigés sont proportionnels aux densités.

Exemple 1.6

Réalisation d'un histogramme et d'un polygone des effectifs


Le responsable des ressources humaines d'une entreprise a relevé la distribution statistique suivante correspondant à l'ancienneté du personnel cadre dans l'entreprise, exprimée en années :

Classes	Effectifs
[6,5 ; 8[	3
[8 ; 9,5[	8
[9,5 ; 11[	12
[11 ; 12,5[	19
[12,5 ; 14[	9
[14 ; 15,5[	5
[15,5 ; 17[	4
Total	60

L'histogramme des effectifs est présenté avec, sur le même graphique, le polygone des effectifs tracé en courbe pleine (voir figure 1.4). Ce polygone permet de représenter la distribution sous la forme d'une courbe ; quand les amplitudes de classes sont égales, on l'obtient en joignant les milieux des bases supérieures de chaque rectangle de l'histogramme par des segments de droite. On adjoint généralement une classe d'effectif nul, de part et d'autre de l'histogramme, afin de respecter la règle de compensation des aires : l'aire totale du domaine situé entre l'axe des x et le polygone est égale à la somme des aires des rectangles de l'histogramme. Elle représente l'effectif total.

Figure 1.4

Histogramme et polygone des effectifs, classes de même amplitude : ancienneté du personnel cadre de l'entreprise.



Modifions légèrement cet exemple en regroupant les deux dernières classes en une seule. Ce regroupement permet de traiter le cas de classes d'amplitudes différentes, puisque ainsi la dernière classe est d'amplitude 3 contre 1,5 pour toutes les autres classes.

Classes	Effectifs
[6,5 ; 8[	3
[8 ; 9,5[	8
[9,5 ; 11[	12
[11 ; 12,5[	19
[12,5 ; 14[	9
[14 ; 17[	9
Total	60

Les classes étant d'amplitudes inégales, il est nécessaire de calculer les amplitudes (a_i), les densités (d_i) puis les effectifs corrigés ($n_i c$) pour chaque classe. Les résultats de ces calculs sont présentés dans la figure 1.5.

Figure 1.5

Calcul des effectifs corrigés dans le cas de classes d'amplitudes inégales.

	A	B	C	D	E
1	Classes	n_i	a_i	d_i	$n_i c$
2	[6,5 ; 8[	3	1,50	2,00	3,0
3	[8 ; 9,5[	8	1,50	5,33	8,0
4	[9,5 ; 11[	12	1,50	8,00	12,0
5	[11 ; 12,5[	19	1,50	12,67	19,0
6	[12,5 ; 14[	9	1,50	6,00	9,0
7	[14 ; 17[	9	3,00	3,00	4,5
8	Total	60			


On peut alors tracer l'histogramme de la figure 1.6 à partir des effectifs corrigés, ainsi que le polygone des effectifs, en trait continu.

Pour tracer le polygone des effectifs, nous avons effectué un découpage artificiel en pseudo-classes d'amplitude 1,5, dont nous avons pris les milieux des bases supérieures de façon à respecter la règle de compensation des aires : les aires des triangles extérieurs au domaine délimité par le polygone sont égales à celles des triangles qui sont situés sous le polygone. Ainsi, l'aire totale du domaine situé sous le polygone des effectifs est égale à l'aire totale des rectangles de l'histogramme.

Ce qui est fait dans cet exemple à partir des effectifs peut également être réalisé à partir des fréquences, afin de tracer l'histogramme et le polygone des fréquences.

Figure 1.6

Histogramme et polygone des effectifs : classes d'amplitudes inégales.



Enfin, il serait inconcevable de ne pas évoquer une variété d'histogramme, la pyramide, dont l'exemple le plus célèbre est la pyramide des âges (voir figure 1.7). Cette variété d'histogramme, où les axes ont été modifiés (classes en ordonnées et effectifs en abscisses), est largement utilisée en démographie. Les classes sont annuelles. Les aires des rectangles représentent le nombre d'hommes ou de femmes vivants et nés l'année considérée, en lecture sur l'axe des abscisses.

3.3 DIAGRAMMES CUMULATIFS

Les notions d'effectifs et de fréquences cumulés nous ont donné l'occasion d'introduire la notion de fonction de répartition, que nous définissons ci-après avant d'évoquer sa représentation graphique.

Définition

Si X est une variable quantitative, on introduit la **fonction de répartition**, qui à tout nombre réel x associe la proportion des individus de la population pour lesquels X est inférieur ou égal à x .

Pour tout x réel, $0 \leq F(x) \leq 1$ (les valeurs de F peuvent également être exprimées en pourcentage).

La première étape de la construction d'une fonction de répartition consiste donc à calculer les fréquences cumulées croissantes, en distinguant deux cas : le discret et le continu.

Fonction de répartition d'une variable discrète

La fonction de répartition d'une variable quantitative discrète est une fonction en escalier, c'est-à-dire constante par intervalle. De plus, elle est croissante de 0 à 1 et définie par :

- Si $x < x_i$, $F(x) = 0$
- Si $x = x_i$, $F(x) = f_{ic}$
- Si $x_i \leq x < x_{i+1}$, $F(x) = f_{ic}$
- Si $x \geq x_r$, $F(x) = 1$

Fonction de répartition d'une variable continue

A priori, la fonction de répartition d'une variable continue n'est connue que pour les extrémités de classes. Cependant, si l'on admet l'hypothèse de répartition uniforme des observations au sein de chaque classe, on peut estimer les valeurs de $F(x)$ par interpolation linéaire. Cela revient à approximer la représentation graphique par une fonction affine par morceaux : concrètement, on trace la courbe en joignant deux points consécutifs connus par un segment de droite (cette courbe est aussi appelée ogive de Galton¹).

Avec cette hypothèse, $F(x)$ représente l'aire située sous l'histogramme des fréquences, à gauche de la valeur x .

Polygones des effectifs cumulés croissants et décroissants

Dans le cas d'une variable continue, on définit les polygones des effectifs (ou des fréquences) cumulés croissants et décroissants ; ils seront utilisés notamment pour déterminer la médiane de la série (voir chapitre 2).

Le polygone des fréquences cumulées croissantes commence au point de coordonnées $(a_i ; 0)$, car la proportion de valeurs inférieures à a_i est nulle. Il est obtenu en joignant les points de coordonnées $(b_i ; f_{ic})$ – il correspond à la restriction de la fonction de répartition aux valeurs de x inférieures ou égales à la borne supérieure de la dernière classe.

Le polygone des fréquences cumulées décroissantes s'obtient de la même façon, en adjoignant le point de coordonnées $(b_r ; 0)$, car, b_r désignant la borne supérieure de la dernière classe, la proportion de valeurs supérieures à b_r est nulle.

Exemple 1.7

Réalisation des polygones des fréquences cumulées croissantes et décroissantes

Le tableau suivant donne la structure de la population chinoise suivant l'âge :

0-14 ans	15-24 ans	25-59 ans	60 ans et plus
21,4 %	16,6 %	51,1 %	10,9 %

Source : ONU, 2005

1. Francis Galton (1822-1911) fut l'un des fondateurs de la biométrie et collabora avec son ami Karl Pearson (1857-1936).

Les fréquences cumulées croissantes et décroissantes sont calculées puis organisées pour correspondre aux bornes des classes (voir figure 1.8).

Figure 1.8


Plages de données des polygones des fréquences cumulées croissantes et décroissantes.

	A	B	C	D	E
1	Classes	f_i	Borne de classe	$f_{i,cc}$	$f_{i,cd}$
2			0	0,00	100,00
3	[0 ; 15[	21,40	15	21,40	78,60
4	[15 ; 25[	16,60	25	38,00	62,00
5	[25 ; 60[	51,10	60	89,10	10,90
6	60 et +	10,90	95	100,00	0,00

À partir de ces données, il est possible de tracer les polygones des fréquences cumulées croissantes et décroissantes (voir figure 1.9).

Figure 1.9

Polygones des fréquences cumulées croissantes et décroissantes de l'âge de la population chinoise.



Conclusion

On retiendra de ce premier chapitre l'importance de la terminologie. On devra savoir identifier, dans un exercice, la population, les variables étudiées et leur nature : qualitative, quantitative discrète ou quantitative continue. On notera que le discret et le continu, en statistique comme en probabilité, nécessitent des traitements différents ; dans le cas continu, on retiendra l'importance de la notion de densité. Par ailleurs, on n'insistera jamais assez sur l'importance des représentations graphiques en statistique ; à l'issue de ce chapitre, on devra maîtriser notamment les histogrammes et les polygones des effectifs (ou des fréquences) cumulés croissants et décroissants.

Les caractéristiques de tendance centrale

1 Le mode

Lors de l'observation de la représentation graphique d'une distribution statistique (diagramme en bâtons ou histogramme), l'œil est souvent attiré par le bâton ou le rectangle le plus haut. Une des valeurs typiques d'une série statistique est le mode (valeur dominante).

Ce mot semble inspiré de « la mode », car il met en évidence la valeur la plus probable de la série.

La courbe « en cloche » de la distribution normale (voir chapitre 4, section 1) en donne une bonne vision.

1.1 PRÉSENTATION

Définition

Le **mode** est la valeur de la variable qui a l'effectif (ou la fréquence) le plus grand. On le note Mo .

En économie, dans les problèmes d'alimentation, de revenu, de logement, etc., le groupe qui a le plus grand poids est celui du mode. Il situe bien la position des valeurs les plus fréquemment rencontrées.

Le repérage du mode n'est pas un problème complexe, mais il faut distinguer le cas d'une variable qualitative ou quantitative discrète du cas d'une variable continue.

Il existe des séries unimodales (un mode) et des séries plurimodales (plusieurs modes).

1.2 VARIABLE QUALITATIVE OU QUANTITATIVE DISCRÈTE

Si la variable est qualitative ou quantitative discrète, on détermine le mode directement en identifiant la modalité de la variable qui correspond à l'effectif maximal (ou à la fréquence maximale).

Le mode d'une série discrète est une valeur de la série. Graphiquement, le mode correspond au bâton le plus long (aux bâtons les plus longs dans le cas des séries plurimodales).

1.3 VARIABLE QUANTITATIVE CONTINUE

Si la variable est quantitative continue, il faut procéder en deux étapes :

1. Détermination de la classe modale (elle n'est pas nécessairement unique), c'est-à-dire celle qui est représentée dans l'histogramme par le rectangle le plus haut : c'est la classe de plus grande densité. On notera que, si les classes sont de même amplitude, la classe modale est celle qui a le plus grand effectif (ou la plus grande fréquence).

Rappel (voir chapitre 1, section 3.2) : la densité d'effectif de la classe i , notée d_i , est le

rapport $d_i = \frac{n_i}{a_i}$, avec n_i l'effectif et a_i l'amplitude de la classe. Cette densité représente

le nombre d'individus par unité d'amplitude.


2. Détermination du mode à l'intérieur de cette classe modale.

Pour une première estimation, le mode peut être approché par le centre de la classe modale. En fait, le mode est l'abscisse du point où la courbe de densité de fréquence atteint son maximum.

Dans la pratique, nous disposons uniquement de l'histogramme. Le mode peut être estimé par la méthode des diagonales : on utilise le trapèze mis en évidence par les deux rectangles encadrant le rectangle modal (voir figure 2.1).

Figure 2.1

Histogramme des effectifs et détermination du mode : structure des âges en 2020, France, prévisions.



Graphiquement, la classe modale est le pic de l'histogramme corrigé (amplitudes égales) et le mode correspond à l'abscisse du point d'intersection des deux diagonales. Il se calcule donc sur les effectifs corrigés (c'est le seul indicateur qui se calcule sur effectifs corrigés).

Dans le cas où les amplitudes de classes sont égales, la classe modale est celle qui a le plus grand effectif (ou la plus grande fréquence). La suite de la démarche est identique.

Soit $[x_1 ; x_2[$ la classe modale, h_1 et h_2 les hauteurs (effectifs corrigés ou densités) des rectangles encadrant le rectangle modal, h la hauteur du rectangle modal et Mo le mode.

Afin de calculer le mode, l'idée est d'abandonner l'hypothèse de répartition uniforme à l'intérieur de la classe modale, qui conduit à retenir le centre de classe. L'hypothèse privilégiée est celle d'une répartition influencée par les valeurs h_1 et h_2 , le mode étant « attiré » du côté du rectangle voisin de plus grande densité. Il est supposé que la densité croît de la valeur h_1 à son maximum h et décroît de h à h_2 avec la même vitesse, ce qui

donne, avec les taux d'accroissement :
$$\frac{h - h_1}{Mo - x_1} = \frac{h - h_2}{x_2 - Mo}.$$

Soit $\frac{k_1}{Mo - x_1} = \frac{k_2}{x_2 - Mo}$, avec k_1 et k_2 les différences : $k_1 = h - h_1$ et $k_2 = h - h_2$.

En effectuant le produit en croix :
$$Mo = \frac{k_2 x_1 + k_1 x_2}{k_1 + k_2}.$$

Le mode apparaît comme la moyenne pondérée de x_1 et x_2 respectivement affectés des coefficients h_2 et k_1 .

Une formule équivalente du mode est donnée par : $Mo = x_1 + \frac{k_1}{k_1 + k_2}(x_2 - x_1)$. Cette formule montre bien, par exemple, le déplacement du mode vers x_1 dans la cas où $k_1 < k_2$, donc où $\frac{k_1}{k_1 + k_2} < 0,5$.

Exemple 2.1

Calcul du mode sur variable quantitative continue

Considérons les prévisions de la structure démographique de la France en 2020 :

Âge	n_i	a_i	d_i
0-19 ans	14 115	20	705,75
20-29 ans	7 403	10	740,3
30-39 ans	7 842	10	784,2
40-49 ans	7 967	10	796,7
50-59 ans	8 281	10	828,1
60-69 ans	7 716	10	771,6
70-79 ans	5 521	10	552,1
80-89 ans	3 074	10	307,4
90-99 ans	878	10	87,8

Source : Insee, projections des ménages à l'horizon 2020 pour la France métropolitaine, juillet 2006

Les amplitudes de classes étant différentes, nous utilisons les densités pour déterminer la classe modale et représenter l'histogramme (voir figure 2.1). La classe modale est donc la classe des 50-59 ans soit $[50 ; 60[$ avec une densité de 828,1.

$x_1 = 50$; $x_2 = 60$; $h = 828,1$; $h_1 = 796,7$; $h_2 = 771,6$; $k_1 = 828,1 - 796,7 = 31,4$; $k_2 = 828,1 - 771,6 = 56,5$.

En appliquant la formule du mode :

$Mo = \frac{k_2 x_1 + k_1 x_2}{k_1 + k_2} = \frac{56,5 \times 50 + 31,4 \times 60}{31,4 + 56,5}$, soit $Mo = 53,57$ ans, soit environ 52 ans et 7 mois.

Le mode est très peu conforme aux conditions de Yule. Il ne se prête pas aux calculs algébriques, et ne dépend pas de tous les termes de la série. Cependant, il reste une valeur centrale importante pour les distributions ayant un effectif important, car il donne la valeur la plus typique.

2 Les moyennes

« Si un individu possédait à une époque donnée toutes les qualités de l'homme moyen, il représenterait tout ce qui est grand, bon et beau », disait Adolphe Quételet¹.

Sans nous attacher à la notion contestée d'« homme moyen » de Quételet, gardons à l'esprit que l'idée de moyenne est une notion abstraite. Quand le statisticien calcule une moyenne, il fabrique en général une grandeur nouvelle, qui a la vocation d'être représentative de toutes les grandeurs considérées, mais qui n'a en général aucune existence réelle. Nous imaginons mal un fabricant de chaussures qui fabriquerait des chaussures correspondant à la taille moyenne.

Quatre types de moyennes sont définies ici : les moyennes arithmétiques et celles, moins utilisées, que sont les moyennes géométriques, harmoniques et quadratiques.

La moyenne arithmétique garde un rôle primordial du fait de sa simplicité de calcul, mais surtout du fait de sa place fondamentale dans la théorie des erreurs d'observation (loi de Laplace-Gauss²) et dans la théorie de la régression (voir chapitre 6).

L'idée fondamentale de la notion de moyenne est que cette dernière vise à représenter des grandeurs inégales par une grandeur unique qui ne change pas la globalité de la situation. Ainsi, dans une entreprise où les personnels ont des salaires différents, la masse salariale resterait inchangée si tous les personnels percevaient le même salaire moyen.

2.1 LA MOYENNE ARITHMÉTIQUE

C'est en astronomie, avec Tycho Brahe³, que la moyenne arithmétique s'impose. Johann Bernoulli⁴ la qualifie dans *l'Encyclopédie* comme le « milieu à prendre entre les observations ».

Cette moyenne, liée à l'addition, est la moyenne la plus couramment utilisée. Elle représente bien l'idée de milieu, d'équilibre, symbolisée par la place du zéro dans les nombres.

Définitions

La moyenne arithmétique est la somme des valeurs observées rapportée au nombre d'observations. Elle se note $\bar{x}$.

La **moyenne arithmétique simple** de n réels (données en tableau brut) correspond à la division de leur somme par leur nombre. Soit $x_1, x_2, \dots, x_n$ les n observations de la variable X (non nécessairement distinctes) : la moyenne arithmétique se note $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$. Cette formule

implique que $\sum_{i=1}^n x_i = n\bar{x}$.

1. Adolphe Quételet (1796-1874), astronome, statisticien belge.

2. Pierre Simon de Laplace (1749-1827), mathématicien, astronome français. Carl Friedrich Gauss (1777-1855), astronome, mathématicien allemand.

3. Tycho Brahe (1546-1601), astronome danois.

4. Johann Bernoulli (1667-1748), mathématicien suisse.

La **moyenne arithmétique pondérée** de r réels (distincts) $x_1, x_2, \dots, x_r$ (données en tableau statistique), affectés respectivement des coefficients n_i , tels que $\sum_{i=1}^r n_i = n$, se note

$$\bar{x} = \frac{1}{n} \sum_{i=1}^r n_i x_i. \text{ Ou encore } \bar{x} = \sum_{i=1}^r f_i x_i.$$

Les probabilistes parlent d'espérance d'une variable aléatoire et notent sa moyenne

$$E(X) = \sum_{i=1}^r p_i x_i, \text{ les probabilités } p_i \text{ se substituant aux fréquences } f_i.$$

Calcul de la moyenne arithmétique dans le cas d'une variable discrète

Exemple 2.2

Calcul d'une moyenne arithmétique pondérée

La répartition des effectifs du préélémentaire dans les établissements publics par âges en 2005-2006 est la suivante :

Âge	n_i	f_i (%)
2 ans	154 141	0,0702
3 ans	667 328	0,3038
4 ans	685 158	0,3119
5 ans	680 202	0,3097
6 ans et plus	9 683	0,0044

Source : ministère de l'Éducation nationale, 2007

On notera qu'*a priori* l'âge est une variable continue ; cependant, l'Éducation nationale présente ici cette variable comme une variable discrète et nous la traiterons ainsi. Par ailleurs, nous prendrons 6 pour la dernière modalité.

Pour calculer la moyenne, il est nécessaire de calculer chacun des $n_i x_i$, avant d'en calculer la somme (voir figure 2.2).

La moyenne est obtenue en divisant la somme des $n_i x_i$ par l'effectif total. L'âge moyen dans les établissements publics de maternelle est : $\bar{x} = \frac{8\,510\,006}{2\,196\,512} = 3,87$ ans. On peut également retrouver cette valeur en calculant chacun des $f_i x_i$ et en effectuant leur somme.

Figure 2.2

Calcul des $n_i x_i$ sous Excel (établissements publics).

	A	B	C	D	E
1	Âge (x_i)	n_i	$n_i x_i$	f_i	$f_i x_i$
2	2	154 141	308 282	0,0702	0,1404
3	3	667 328	2 001 984	0,3038	0,9114
4	4	685 158	2 740 632	0,3119	1,2477
5	5	680 202	3 401 010	0,3097	1,5484
6	6	9 683	58 098	0,0044	0,0265
7	Somme	2 196 512	8 510 006	1,00	3,87

De même, en calculant chacun des $f_i x_i$ et en effectuant leur somme, on trouve que l'âge moyen dans les établissements privés de maternelle est : $\bar{x} = 3,8$ ans (voir figure 2.2).

Calcul de la moyenne arithmétique dans le cas d'une variable continue

Les définitions et formules des moyennes arithmétiques simple et pondérée sont les mêmes que celles utilisées dans le cas d'une variable discrète. La méthode reste identique à l'exception de l'utilisation de l'hypothèse de répartition uniforme à l'intérieur des classes et de concentration au centre des classes, ce qui autorise le calcul de la moyenne à partir des centres de classes.

Exemple 2.3

Calcul d'une moyenne arithmétique pondérée sur variable continue en classe

Reprenons les prévisions de l'Insee à l'horizon 2020 (voir exemple 2.1) et calculons l'âge moyen prévisible. Pour calculer les $n_i x_i$, il faut préalablement calculer les centres de classes x_i . Si a_i et b_i représentent respectivement les bornes inférieure et supérieure des classes, alors le centre de classe $x_i = \frac{a_i + b_i}{2}$. Une fois les x_i connus, il convient de calculer chacun des $f_i x_i$, avant d'en faire la somme (voir figure 2.3).

Figure 2.3

Calcul des $f_i x_i$ sous Excel.

	A	B	C	D	E
1	a_i	b_i	x_i	f_i	$f_i x_i$
2	0	20	10	0,225	2,25
3	20	30	25	0,118	2,95
4	30	40	35	0,124	4,34
5	40	50	45	0,127	5,72
6	50	60	55	0,132	7,26
7	60	70	65	0,123	8,00
8	70	80	75	0,088	6,60
9	80	90	85	0,049	4,17
10	90	100	95	0,014	1,33
11	Somme			1,000	42,61

$\bar{x} = 42,61$, l'âge moyen est de 42,61 ans.

Propriétés de la moyenne arithmétique

La moyenne arithmétique possède la propriété de linéarité : $\overline{x + y} = \bar{x} + \bar{y}$ et $\overline{ax} = a\bar{x}$, a étant une valeur constante.

Par exemple, soit une entreprise dans laquelle le revenu des personnels se compose d'un salaire x et d'une prime y , le salaire moyen mensuel étant de 3 500 euros et la prime moyenne mensuelle de 200 euros. Le revenu moyen mensuel sera de 3 700 euros. De même, si tous les salaires sont augmentés de 5 %, le salaire moyen deviendra : $3\,500 \times 1,05 = 3\,675$ euros.

Si toutes les valeurs des observations sont identiques, la moyenne de ces observations est égale à cette valeur commune. Autrement dit, la moyenne d'une variable statistique constante est égale à elle-même.

D'où : $\overline{ax + b} = a\bar{x} + b$, a et b étant des valeurs constantes. Cela permet notamment de changer d'unité, ou d'origine, toute transformation linéaire effectuée sur la variable étant répercutée sur la moyenne.

La moyenne des écarts à la moyenne est nulle.

$$\sum_{i=1}^r n_i (x_i - \bar{x}) = \sum_{i=1}^r n_i x_i - \sum_{i=1}^r n_i \bar{x} = \sum_{i=1}^r n_i x_i - n \bar{x} = 0, \text{ car selon la formule de la moyenne}$$

$$\frac{1}{n} \sum_{i=1}^r n_i x_i = \bar{x}, \text{ soit } \sum_{i=1}^r n_i x_i = n \bar{x}.$$

Cela explique pourquoi nous choisirons la moyenne des écarts au carré pour mesurer la dispersion, encore appelée variance.

La moyenne arithmétique dépend de tous les termes de la série, elle se prête bien aux calculs, c'est un bon indicateur de tendance centrale au sens de Yule. En revanche, elle présente l'inconvénient d'être très sensible aux valeurs extrêmes. C'est pourquoi elle est qualifiée d'indicateur peu robuste.

2.2 LES AUTRES MOYENNES

La moyenne géométrique : moyenne de la multiplication

Introduisons cette moyenne par un exemple : soit une pièce rectangulaire de 16 mètres sur 9 mètres. Quelle serait la dimension du côté d'une pièce carrée de même aire ?

Si g désigne notre inconnue, $g^2 = 16 \times 9$ soit g étant un réel positif, $g = \sqrt{16 \times 9} = 12$; ce nombre est appelé la moyenne géométrique de 16 et 9.

Définitions

La **moyenne géométrique simple**, notée g , de n réels positifs est la racine $n^{\text{ième}}$ de leur produit : $G = \sqrt[n]{\prod_{i=1}^n x_i}$. Ou encore $G = \sqrt[n]{x_1 \times x_2 \times \dots \times x_n} = (x_1 \times x_2 \times \dots \times x_n)^{\frac{1}{n}}$.

La **moyenne géométrique pondérée** de r réels positifs, affectés respectivement des coefficients n_i , tels que $\sum_{i=1}^r n_i = n$, se note G , tel que $G = \sqrt[n]{\prod_{i=1}^r x_i^{n_i}}$.

Ou encore $G = \sqrt[n]{x_1^{n_1} \times x_2^{n_2} \times \dots \times x_r^{n_r}} = (x_1^{n_1} \times x_2^{n_2} \times \dots \times x_r^{n_r})^{\frac{1}{n}} = x_1^{\frac{n_1}{n}} \times x_2^{\frac{n_2}{n}} \times \dots \times x_r^{\frac{n_r}{n}}$.

La moyenne géométrique sera utilisée dans le chapitre 8 sur les indices (indice de Fisher). Par ailleurs, elle est indispensable dans les calculs de taux de croissance ; elle donne le coefficient multiplicateur moyen.

Exemple 2.4

Calcul d'une moyenne géométrique pondérée

Supposons que la population d'un pays ait augmenté trois années de suite de 4 % et deux années de suite de 5 %, l'augmentation moyenne sera donnée par $1 + t = \sqrt[5]{1,04^3 \times 1,05^2}$, soit un taux de croissance annuel moyen $t = (1,04^3 \times 1,05^2)^{\frac{1}{5}} - 1$, soit environ 4,40 % par an.

La moyenne géométrique est très liée à la moyenne arithmétique. En effet : $Ln(g) = \frac{1}{n} \sum_{i=1}^r n_i Ln(x_i)$. Ainsi, la moyenne géométrique est égale à la moyenne arithmétique pondérée des logarithmes népériens.

Nous noterons également que, sur la courbe de la fonction exponentielle, en prenant deux points d'abscisses respectives a et b, l'ordonnée du point d'abscisse $\frac{a+b}{2}$ est

$$e^{\frac{a+b}{2}} = \sqrt{e^a \times e^b}, \text{ soit une moyenne géométrique.}$$

La moyenne harmonique : moyenne de l'inverse

Si la moyenne arithmétique s'impose dans de nombreuses situations, le recours à d'autres moyennes est parfois indispensable.

Prenons un exemple classique : supposons qu'un aller-retour Paris-Deauville soit effectué avec une vitesse moyenne de 130 km/h à l'aller et de 80 km/h au retour. Que penser de la vitesse moyenne sur l'aller-retour ?

Soit d la distance Paris-Deauville, t le temps du trajet et v la vitesse. Alors $v = \frac{d}{t}$. D'où

$$v = \frac{2d}{\frac{d}{130} + \frac{d}{80}} = \frac{2}{\frac{1}{130} + \frac{1}{80}} = 99,04 \text{ km/h, et non } 105 \text{ km/h comme le donnerait la}$$

moyenne arithmétique. Nous pouvons également écrire : $\frac{2}{v} = \frac{1}{130} + \frac{1}{80}$, v s'appelant la moyenne harmonique des vitesses.

Définitions

La **moyenne harmonique simple** de n nombres réels non nuls est le réel noté H et défini par :

$$\frac{n}{H} = \sum_{i=1}^n \frac{1}{x_i} \text{ soit } H = \frac{1}{\frac{1}{n} \sum_{i=1}^n \frac{1}{x_i}}, \text{ l'inverse de la moyenne arithmétique des inverses. Ou encore}$$

$$H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}.$$

La **moyenne harmonique pondérée** de r nombres réels non nuls, affectés respectivement des coefficients n_i , tels que $\sum_{i=1}^r n_i = n$, est le réel noté h et défini par : $\frac{n}{H} = \sum_{i=1}^r \frac{n_i}{x_i}$ soit

$$H = \frac{1}{\frac{1}{n} \sum_{i=1}^r \frac{n_i}{x_i}}, \text{ soit l'inverse de la moyenne arithmétique pondérée de leurs inverses. Ou}$$

$$\text{encore } H = \frac{n}{\sum_{i=1}^r \frac{n_i}{x_i}}.$$

La moyenne harmonique sera également utilisée dans le chapitre 8 sur les indices (indice de Paasche).

La moyenne quadratique

Le mot quadratique, qui vient du latin, évoque le carré et est utilisé pour désigner la puissance deux.

Partons d'un exemple simple : supposons un appartement composé de deux pièces carrées de côtés respectifs a et b ($a \neq b$) et cherchons la mesure du côté Q des pièces d'un appartement de même surface, mais composé de deux pièces identiques carrées. On

$$\text{aura : } 2Q^2 = a^2 + b^2 \text{ soit } Q = \sqrt{\frac{a^2 + b^2}{2}}.$$

La moyenne quadratique, ou moyenne d'ordre 2, est la moyenne qui sert à définir l'écart-type d'une variable statistique, que nous utiliserons lors de l'étude de la dispersion.

Définitions

La **moyenne quadratique simple** de n nombres réels, notée Q , correspond à la moyenne arithmétique de leurs carrés : $Q = \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}$. Ou encore $Q = \sqrt{\frac{x_1^2 + x_2^2 + \dots + x_n^2}{n}}$.

La **moyenne quadratique pondérée**, notée Q , de r nombres réels, affectés respectivement des coefficients n_i , tels que $\sum_{i=1}^r n_i = n$, correspond à la moyenne arithmétique pondérée de leurs carrés : $Q = \sqrt{\frac{1}{n} \sum_{i=1}^r n_i x_i^2}$. Ou encore $Q = \sqrt{\frac{n_1 x_1^2 + n_2 x_2^2 + \dots + n_r x_r^2}{n}}$.

Focus 2.1

Remarques sur les moyennes

1. Une moyenne représente toujours un « centre » d'une série de données. Soit x_{Min} et x_{Max} respectivement la plus petite et la plus grande valeur de la série. Les moyennes de la série statistique appartiennent toujours à l'intervalle $[x_{Min} ; x_{Max}]$.
2. Il est important de retenir l'ordre de ces moyennes : $x_{Min} \leq H \leq G \leq \bar{x} \leq Q \leq x_{Max}$. Cette remarque, qui servira notamment pour comparer les indices synthétiques, est aisément démontrable pour deux réels a et b . Vérifions-le avec un exemple : $a = 9$ et $b = 16$
donne : $H = \frac{288}{25} = 11,52$. $G = 12$; $\bar{x} = 12,5$ et $Q = \sqrt{\frac{256 + 81}{2}} = 12,98$.
3. Les moyennes sont des indicateurs qualifiés de peu robustes en ce sens qu'ils sont sensibles aux valeurs extrêmes.

3 Les quantiles

Partons d'un exemple : « En 2005, 10 % des salariés à temps complet du secteur privé et semi-public gagnent un salaire annuel net inférieur à 12 506 € » (source : Insee, DADS, 2005).

On dit que 12 506 constitue le quantile d'ordre 0,10 de la série des salaires considérée.

Si p est un réel de l'intervalle $]0 ; 1[$, on lui associe la valeur de la série, notée $Q(p)$, appelée quantile d'ordre p . La proportion des valeurs de la série inférieures ou égales à $Q(p)$ est supérieure ou égale à p .

La médiane est un quantile particulier qui sépare la population en deux groupes d'effectifs égaux.

3.1 LA MÉDIANE

Il est clair que l'idée de partager la série en deux groupes ayant exactement le même effectif n'est pas toujours réalisable, aussi la définition de la médiane doit-elle être affinée.

Définition

La **médiane**, notée Me , est la plus petite valeur de la série* pour laquelle le nombre d'observations inférieures ou égales à cette valeur représente au moins 50 % de l'effectif total de la série.

C'est le quantile d'ordre 0,5.

* Convention : dans le cas d'une série discrète comportant un nombre pair d'observations, la médiane n'est pas nécessairement une valeur observée (voir exemple 2.6).

Ainsi, il y a au moins 50 % des observations ayant une valeur inférieure ou égale à la médiane et au moins 50 % des observations ayant une valeur supérieure ou égale à la médiane.

On détermine la médiane à l'aide des effectifs cumulés croissants, à partir de la série des valeurs ordonnées dans l'ordre croissant. Il convient de distinguer le cas d'une variable présentée sous forme de données brutes du cas d'une variable présentée dans un tableau statistique. Dans ce dernier cas, on distinguera le cas discret et le cas continu.

La médiane d'une série de données brutes

Tout d'abord la série doit être classée dans l'ordre croissant des valeurs.

La détermination directe ou non de la médiane dépend du nombre de données brutes.

1. Si ce nombre est impair, il est possible de déterminer directement la médiane.
2. Si ce nombre est pair, la médiane est déduite de l'intervalle médian.

Calcul 1 : si la série brute comporte un nombre *impair* d'observations, noté $n = 2p + 1$, la médiane est la valeur centrale de la série (ordonnée en sens croissant), donc la $(p + 1)^{\text{ième}}$ observation.

Exemple 2.5

Calcul de la médiane, nombre impair de données brutes

Le tableau suivant donne le taux d'emploi (en pourcentage) des jeunes de 15 à 24 ans, en 2005, dans les sept pays de l'Union européenne ayant le plus fort taux.

Pays	Taux d'emploi
Allemagne	42
Pays-Bas	65,2
Autriche	53,1

Pays	Taux d'emploi
Irlande	48,7
Royaume-Uni	54
Danemark	62,3
Finlande	40,5

Source : Insee, juillet 2006

Classons tout d'abord les modalités par ordre croissant. Dans notre exemple, ces modalités sont au nombre de $n = 7$, c'est-à-dire un nombre impair, et $p = 3$, donc la médiane est la valeur centrale de la série ordonnée, c'est-à-dire la 4^e observation : 40,5 – 42 – 48,7 – 53,1 – 54 – 62,3 – 65,2. La médiane est $Me = 53,1$.

Calcul 2 : si la série brute comporte un nombre *pair* d'observations, noté $n = 2p$, il convient de déterminer l'intervalle médian, constitué par les observations de rang p et $p + 1$ de la série ordonnée. Par convention, la médiane est le milieu de cet intervalle médian.

Exemple 2.6

Calcul de la médiane, nombre pair de données brutes

Reprenons l'exemple précédent (voir exemple 2.5) et rajoutons la France avec un taux de 30,1 %. Le nombre de modalités devient $n = 8$, donc $p = 4$. L'intervalle médian est constitué de la 4^e et de la 5^e observation, c'est donc l'intervalle médian [48,7 ; 53,1]. Par

convention, $Me = \frac{48,7 + 53,1}{2} = 50,9$.

La médiane dans un tableau statistique

Pour calculer la médiane à partir d'un tableau statistique, il convient de distinguer deux cas :

1. Soit la variable est présentée comme un caractère discret.
2. Soit la variable est présentée comme un caractère continu.

Calcul 1 : Dans le premier cas, les modalités de la variable sont des valeurs isolées. La détermination de la médiane se fait directement à l'aide des effectifs cumulés croissants (voir figure 2.4).

Exemple 2.7

Calcul de la médiane pour une variable présentée comme un caractère discret

Le tableau suivant donne le nombre d'enfants de moins de 25 ans par famille, en France métropolitaine en 2005 :

Nombre d'enfants	n_i (milliers)
1	3 714
2	3 369
3	1 237
4 ou +	410

Source : Insee, enquêtes de recensement, 2004-2006

Figure 2.4

Effectifs cumulés croissants.

	A	B	C
1	Age (x _i)	n _i Public	n _i cc
2	2	154 141	154 141
3	3	667 328	821 469
4	4	685 158	1 506 627
5	5	680 202	2 186 829
6	6	9 683	2 196 512
7	Somme	2 196 512	

Le nombre d'observations est pair, donc l'intervalle médian est constitué par les deux observations centrales, c'est-à-dire de rangs respectifs $p = \frac{n}{2} = \frac{8730000}{2} = 4365000$ et $p + 1 = 4365001$. Les effectifs cumulés croissants nous montrent que ces observations sont dans la modalité 2, donc que la médiane, leur moyenne arithmétique, est 2. Il y a au moins 50 % des familles ayant un nombre d'enfants inférieur ou égal à 2 et au moins 50 % des familles ayant un nombre d'enfants supérieur ou égal à 2.

Calcul 2 : Dans le second cas, les modalités de la variable sont des classes. La détermination de la médiane repose sur l'hypothèse que les observations sont réparties uniformément au sein de chaque classe. La médiane est alors définie par $F(\text{Me}) = 0,50$, où F désigne la fonction de répartition. Son calcul se fait en deux temps :

1. Localisation de la classe médiane à l'aide des effectifs cumulés croissants ou des fréquences cumulées croissantes.
2. Calcul de la médiane par interpolation linéaire (voir focus 2.2).

Focus 2.2

Interpolation linéaire

Le mot « inter » signifie que nous opérons entre deux valeurs connues, appelées pôles. Le mot « linéaire » évoque la droite.

Supposons une fonction f définie sur un segment $[a ; b]$, et dont nous connaissons les valeurs $f(a)$ et $f(b)$, le problème étant d'estimer la valeur de f en un point x du segment $[a ; b]$. Le principe de l'interpolation linéaire est donc de supposer l'alignement des points A , B et M dont les coordonnées sont $A(x_A ; y_A)$; $B(x_B ; y_B)$; $M(x_M ; y_M)$.

Cet alignement des points A , B et M est représenté sur la figure 2.5.

L'alignement des points A , B et M se traduit par l'égalité des coefficients directeurs, ou encore par l'égalité des rapports des distances, en utilisant le théorème de Thalès.

$$\frac{AB}{AM} = \frac{AB'}{AM'} = \frac{AB''}{AM''}, \text{ soit } \frac{y_B - y_A}{x_B - x_A} = \frac{y_M - y_A}{x_M - x_A}, \text{ ce qui donne, après un produit en croix :}$$


$$y_M = y_A + \frac{y_B - y_A}{x_B - x_A}(x_M - x_A).$$

Par exemple, déterminons une valeur approchée de $\sqrt{3}$ ($= 1,732$) par interpolation linéaire sur le segment $[1 ; 4]$ (voir figure 2.5). L'interpolation linéaire donne : $\frac{2-1}{4-1} = \frac{\sqrt{3}-1}{3-1}$ soit :

$$\sqrt{3} = 1 + \frac{2}{3} = \frac{5}{3} = 1,667.$$

Figure 2.5

Alignement et égalité des coefficients directeurs.



Exemple 2.8

Calcul de la médiane pour une variable présentée comme un caractère continu

Soit le nombre de personnes de plus de 15 ans ayant un niveau d'études supérieures (voir figure 2.6).

Figure 2.6

Calcul des $n_{i,cc}$ sous Excel.

	A	B	C	D
1	a_i	b_i	n_i	$n_{i,cc}$
2	15	20	7 573	7 573
3	20	25	563 044	570 617
4	25	30	1 594 191	2 164 808
5	30	40	2 488 412	4 653 220
6	40	60	3 063 199	7 716 419
7	60	80	974 740	8 691 159
8	Somme		8 691 159	


Source : Insee, recensement de la population, 1999

Le calcul de l'effectif moitié, 4 345 579,5, et les effectifs cumulés croissants permettent de localiser la médiane dans l'intervalle des 30-40 ans.

Le polygone des effectifs cumulés croissants permet une visualisation graphique de la médiane (voir figure 2.7). Soit les trois points A (30 ; 2 164 808), B (40 ; 4 653 220) et M (Me ; 4 345 579,5).

Figure 2.7

Médiane et effectifs cumulés par âges des personnes de plus de 15 ans ayant un niveau d'études supérieures.



Nous pouvons écrire l'alignement de ces trois points par égalité des coefficients directeurs (interpolation linéaire ; voir focus 2.2) : $\frac{4\,653\,220 - 2\,164\,808}{40 - 30} = \frac{4\,345\,579,5 - 2\,164\,808}{Me - 30}$, soit $\frac{2\,488\,412}{10} = \frac{2\,180\,771,5}{Me - 30}$, ce qui donne, en effectuant le produit en croix : $Me = \frac{2\,180\,771,5}{248\,841,2} + 30 = 38,76$ ans.

La médiane est à relier à la notion de fonction de répartition, fonction définie de $\mathbb{R}$ dans $[0 ; 1]$, extrêmement importante en probabilité. Pour une variable statistique continue, la fonction de répartition se définit par : $F(x) = P(X \leq x)$, qui donne la proportion des individus de la population pour lesquels la variable statistique prend une valeur inférieure ou égale à x . Ainsi : $F(Me) = 0,50$.

La médiane ne satisfait pas bien aux conditions de Yule. Elle dépend du nombre de termes, mais pas de leur grandeur, et est inadaptée aux calculs. Elle présente cependant le grand avantage d'être insensible à l'influence des termes extrêmes, et donc d'être robuste.

3.2 LES QUANTILES : GÉNÉRALISATION DE LA MÉDIANE

Les quantiles

Définition

On suppose que les modalités de la série statistique sont rangées dans l'ordre croissant.

Soit p un réel tel que $0 < p < 1$, on lui associe la valeur de la série*, notée $Q(p)$, appelée quantile d'ordre p . $Q(p)$ est la plus petite valeur de la série pour laquelle la proportion des observations inférieures ou égales à $Q(p)$ est au moins égale à p .

* Convention : dans le cas d'une série discrète comportant un nombre pair d'observations, le quantile d'ordre $0,50$ sera pris égal à la médiane.

La proportion d'observations inférieures ou égales à $Q(p)$ est au moins égale à p et la proportion d'observations supérieures ou égales à $Q(p)$ est au moins égale à $(1 - p)$.

En plus de la médiane, fréquemment utilisée, nous présentons ici les quantiles les plus courants :

- les trois quartiles partagent la série en quatre groupes comprenant chacun 25 % des observations ;
- les neuf déciles partagent la série en dix groupes comprenant chacun 10 % des observations ;
- les quatre-vingt-dix-neuf centiles partagent la série en cent groupes comprenant chacun 1 % des observations.

Les quartiles

Définition

Les **quartiles** partagent la population ou l'échantillon en quatre groupes comprenant chacun 25 % des observations.

Au nombre de trois, ils se notent Q_1 , Q_2 et Q_3 .

- Q_1 est le quantile d'ordre 0,25 : au moins 25 % des observations sont inférieures ou égales à Q_1 et au moins 75 % supérieures ou égales à Q_1 .
- Q_2 est le quantile d'ordre 0,50 : au moins 50 % des observations sont inférieures ou égales à Q_2 et au moins 50 % supérieures ou égales à Q_2 ; Q_2 est égal à la médiane.
- Q_3 est le quantile d'ordre 0,75 : au moins 75 % des observations sont inférieures ou égales à Q_3 et au moins 25 % supérieures ou égales à Q_3 .
- Dans le cas continu, on se réfère à la fonction de répartition : $F(Q_1) = 0,25$; $F(Q_2) = 0,5$ et $F(Q_3) = 0,75$.

La détermination des quartiles se fait comme pour la médiane, avec une interpolation linéaire dans le cas continu, les quartiles pouvant être déterminés grâce au polygone des fréquences ou des effectifs cumulés croissants.

Exemple 2.9

Calcul d'un quartile dans un tableau statistique contenant une variable continue

Reprenons l'exemple 2.8, traité pour la médiane, concernant le niveau d'études des personnes de plus de 15 ans, et déterminons Q_1 . Après avoir calculé $\frac{n}{4} = 2\,172\,789,75$, nous en déduisons que Q_1 appartient à la classe des 30-40 ans. Il reste à effectuer l'interpolation linéaire qui donne :

$$\frac{4\,653\,220 - 2\,164\,808}{40 - 30} = \frac{2\,172\,789,75 - 2\,164\,808}{Q_1 - 30}, \text{ soit } Q_1 = 30,03 \text{ ans, ce qui signifie que}$$

25 % de cette population a un âge inférieur ou égal à 30,03 ans.

Les déciles

Définition

Les **déciles** partagent la population ou l'échantillon en dix groupes comprenant chacun 10 % des observations.

Au nombre de neuf, ils se notent : D_1 , D_2 , D_3 , D_4 , D_5 , D_6 , D_7 , D_8 et D_9 .

- D_1 est le quantile d'ordre 0,10 : au moins 10 % des observations sont inférieures ou égales à D_1 et au moins 90 % des observations sont supérieures ou égales à D_1 .
- D_2 est le quantile d'ordre 0,20 : au moins 20 % des observations sont inférieures ou égales à D_2 et au moins 80 % des observations sont supérieures ou égales à D_2 .
- D_9 est le quantile d'ordre 0,90 : au moins 90 % des observations sont inférieures ou égales à D_9 et au moins 10 % des observations sont supérieures ou égales à D_9 .

Dans le cas continu, on se réfère à la fonction de répartition : $F(D_1) = 0,1$; $F(D_2) = 0,2$; ... ; $F(D_9) = 0,9$.

La détermination des déciles est faite selon le même processus que celui utilisé pour les quartiles.

Les centiles

Définition

Les **centiles** partagent la population ou l'échantillon en cent groupes comprenant chacun 1 % des observations.

Au nombre de quatre-vingt-dix-neuf, ils se notent : $C_1, C_2, \dots, C_{99}$.

- C_1 est le quantile d'ordre 0,01 : au moins 1 % des observations sont inférieures ou égales à C_1 et au moins 99 % des observations sont supérieures ou égales à C_1 .
- C_{99} est le quantile d'ordre 0,99 : au moins 99 % des observations sont inférieures ou égales à C_{99} et au moins 1 % des observations sont supérieures ou égales à C_{99} .
- Dans le cas continu : $F(C_1) = 0,01$; $F(C_2) = 0,02$; ... ; $F(C_{99}) = 0,99$.

La détermination des centiles est faite selon le même processus que celui utilisé pour les quartiles.

Focus 2.3

Positions relatives de la moyenne arithmétique, du mode et de la médiane


La moyenne arithmétique, le mode et la médiane sont trois paramètres de position qui permettent de préciser la forme de la distribution (voir figure 2.8) :

- Lorsque le diagramme de la distribution est symétrique, ces trois paramètres de position sont confondus, comme dans le cas d'une distribution probabiliste normale ou gaussienne (voir chapitre 4, section 1) où la valeur centrale s'impose.
- Lorsque la distribution est asymétrique, ou oblique, le mode est par définition au sommet de la courbe des fréquences. La moyenne, comme un centre d'inertie, attirée par les termes extrêmes, se déplace vers la zone où la courbe est le plus étirée. La médiane reste située entre ces deux valeurs. Ce type de graphique évoque notamment la distribution binomiale. Dans ce cas le choix d'une valeur centrale est beaucoup moins évident et exige de la circonspection.

Nous n'oublions jamais en statistiques que l'interprétation et la présentation des calculs exigent une grande honnêteté intellectuelle : « Les chiffres sont des innocents, qui, sous la sollicitation, sous la torture, avouent très vite ce qu'on leur demande, quitte à se rétracter plus tard » (Alfred Sauvy¹).

Figure 2.8

Histogramme, densité de probabilité et valeurs centrales.



1. Alfred Sauvy (1898-1990), économiste et sociologue français, fut directeur de l'INED (Institut national d'études démographiques).

Karl Pearson¹ a introduit, à la fin du XIX^e siècle, la relation empirique suivante : $Me - Mo = 2 \times (\bar{x} - Me)$. Elle est valable pour les distributions unimodales, pas trop asymétriques, et permet une estimation rapide d'un paramètre à partir des deux autres.

Focus 2.4

Les fonctions Excel

Pour faire la moyenne arithmétique d'une variable : appelez la fonction MOYENNE dans la cellule où vous souhaitez faire apparaître le résultat. Puis, à l'aide de votre curseur, sélectionnez les valeurs dans la liste d'arguments. Cette fonction permet d'effectuer uniquement une moyenne simple.

Pour faire la moyenne harmonique d'une variable : appelez la fonction MOYENNE.HARMONIQUE dans la cellule où vous souhaitez faire apparaître le résultat. Puis, à l'aide de votre curseur, sélectionnez les valeurs dans la liste d'arguments. Cette fonction permet d'effectuer uniquement une moyenne simple.

Pour faire la moyenne géométrique d'une variable : appelez la fonction MOYENNE.GEOMETRIQUE dans la cellule où vous souhaitez faire apparaître le résultat. Puis, à l'aide de votre curseur, sélectionnez les valeurs dans la liste d'arguments. Cette fonction permet d'effectuer uniquement une moyenne simple.

Focus 2.5

Les fonctions de la calculatrice

Avant tout calcul statistique, n'oubliez pas d'effacer les listes : appuyez sur la touche **[STAT]**, puis **ClrList L1,L2,L3**, et validez avec **[ENTER]**. La calculatrice indique alors « done », pour signifier qu'elle a effacé ces trois listes.

Pour effectuer la moyenne arithmétique simple d'une variable : saisissez les modalités dans la colonne L1 du tableau. Appuyez sur la touche **[STAT]**, puis, dans le menu CALC, appelez la fonction 1-Var Stats. Validez avec **[ENTER]**. La moyenne s'affiche sur l'écran, entre autres résultats.

Pour effectuer une moyenne pondérée : saisissez les modalités dans la colonne L1, saisissez les effectifs ou les fréquences dans la colonne L2, puis, dans le menu CALC, appelez la fonction 1-Var Stats, puis indiquez dans l'ordre L1, L2, et validez avec **[ENTER]**.

Pour effectuer le produit de deux colonnes de même dimension, L1 et L2 : mettez par exemple la colonne L3 en surbrillance et tapez **L1×L2**. Le produit des deux colonnes s'affiche dans la colonne L3.

Pour effectuer le produit des éléments d'une colonne : placez le curseur dans la cellule Li (1) (première cellule de la liste i où vous souhaitez faire apparaître le produit). Appuyez sur les touches **[2ND]** et **[LIST]**, puis, dans le menu MATH, appelez la fonction Prod(. Indiquez la colonne Lj dont vous souhaitez calculer le produit des éléments, fermez la parenthèse et validez avec **[ENTER]**.

1. Karl Pearson (1857-1936), mathématicien, statisticien anglais, fondateur avec Galton de la revue *Biometrika*.

Pour calculer la racine $n^{\text{ième}}$ d'une cellule : placez le curseur dans la cellule Li (1) où vous souhaitez faire apparaître la racine $n^{\text{ième}}$. Appuyez sur la touche **MATH**, appelez la fonction $\sqrt[n]{}$. Indiquez la cellule dont vous souhaitez calculer la racine $n^{\text{ième}}$ et validez avec **ENTER**.

Vous pouvez également utiliser la propriété $\sqrt[n]{x} = x^{\frac{1}{n}}$ et vous ramener à un calcul de puissance, en tapant $x^{(1/n)}$.

Conclusion

Nous voyons ainsi que nous serons amenés à faire de nombreux calculs de valeurs centrales pour analyser une série statistique. Nous devons choisir parmi ces valeurs celles qui par leurs qualités correspondent au contexte de l'étude.

La moyenne arithmétique est généralement pertinente si la série est suffisamment longue et homogène. Elle varie peu d'un échantillon à l'autre. La médiane est très simple à calculer, mais est plus sensible aux fluctuations d'échantillonnage. Elle participe bien à la description de la série et élimine l'effet des valeurs aberrantes. Le mode a un but pratique évident : il indique la valeur la plus typique. Par ailleurs, il est incontournable pour les séries asymétriques. Ces paramètres qui participent à une description synthétique de la série doivent toujours être visualisés sur les différentes représentations graphiques. Nous reviendrons dans le chapitre suivant sur l'importance des quartiles et leur rôle dans la représentation graphique des séries par des boîtes à moustaches.

Les caractéristiques de dispersion

1 Les caractéristiques simples

L'étendue, les intervalles interquantiles et l'écart absolu moyen sont qualifiés de simples, car ces caractéristiques restent limitées dans leur construction et leur utilisation, au regard de la notion de variance (exposée dans la seconde partie de ce chapitre).

1.1 L'ÉTENDUE

La première mesure de la dispersion d'une distribution est l'étendue. Cette mesure est la plus simple des caractéristiques de dispersion ; dans le langage courant, on parle d'éventail, ou de fourchette, ou d'intervalle de variation de la série.

Définition

L'**étendue** d'une série est la différence entre la plus grande et la plus petite valeur observée.

Elle est notée : $E = \text{Max}(x_i) - \text{Min}(x_i)$.

L'étendue permet une approche aisée de la dispersion d'une variable, mais sa signification reste très limitée, car elle ne prend en compte que les deux valeurs extrêmes de la série. Or, ces valeurs extrêmes peuvent être mal connues, voire aberrantes ou erronées.

Par ailleurs, l'étendue n'est pas indépendante de l'effectif observé et peut donner une vision faussée de la dispersion.

Enfin, dans le cas de séries continues, l'étendue n'est pas connue avec exactitude, puisque la perte d'information due au regroupement en classes ne permet pas de connaître les valeurs minimales et maximales réellement prises par la variable.

1.2 LES INTERVALLES ET ÉCARTS INTERQUANTILES

Définitions

Il existe trois intervalles et écarts interquantiles :

- L'intervalle interquartile $[Q_1 ; Q_3]$ représente la zone centrale de la population comprenant 50 % de la série ; l'amplitude de cet intervalle est appelée **écart interquartile** et on note : $EIQ = Q_3 - Q_1$.
- L'intervalle interdécile $[D_1 ; D_9]$ représente la zone centrale de la population comprenant 80 % de la série ; l'amplitude de cet intervalle est appelée **écart interdécile** et on note : $EID = D_9 - D_1$.
- L'intervalle intercentile $[C_1 ; C_{99}]$ représente la zone centrale de la population comprenant 98 % de la série ; l'amplitude de cet intervalle est appelée **écart intercentile** et on note : $EIC = C_{99} - C_1$.

Exemple 3.1

Calcul de l'écart interquartile

Reprenons l'exemple 2.8 du chapitre précédent concernant le niveau d'études supérieures des personnes de plus de 15 ans. Dans cet exemple, $Q_1 = 30,03$ ans. En procédant au calcul de Q_3 , nous trouvons $Q_3 = 52,18$ ans. Ainsi, $EIQ = 52,18 - 30,03 = 22,15$ ans, soit environ 22 ans et 2 mois.

Par rapport à l'étendue, l'écart interquartile présente l'avantage d'écarter les valeurs extrêmes, mais l'inconvénient de laisser de côté 50 % des données. C'est pourquoi on préfère habituellement l'intervalle interdécile, $EID = D$ qui comprend 80% de la population.

1.4 L'ÉCART ABSOLU MOYEN

L'écart absolu moyen est le paramètre de dispersion le plus simple qui mesure les fluctuations de la série par rapport à la moyenne.

Définition

L'**écart absolu moyen** de n observations est la moyenne arithmétique des valeurs absolues des écarts à la moyenne : $e_a = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$.

L'**écart absolu moyen** de n observations, ordonnées dans un tableau statistique $(x_i ; n_i)$, présentant r modalités, est la moyenne arithmétique pondérée des valeurs absolues des écarts à la moyenne : $e_a = \frac{1}{n} \sum_{i=1}^r n_i |x_i - \bar{x}|$, r désignant le nombre de modalités, avec $n = \sum_{i=1}^r n_i$.

La valeur absolue des écarts à la moyenne est utilisée afin d'empêcher que les écarts positifs ne se compensent avec les écarts négatifs. En effet, par cette compensation, la somme des écarts à la moyenne est nulle : $\sum_{i=1}^r n_i (x_i - \bar{x}) = 0$.

L'écart absolu moyen présente l'avantage de prendre en compte toutes les valeurs de la série. Il a été introduit par Laplace avant la variance et est utilisé notamment dans la méthode d'estimation L1, méthode alternative à la méthode des moindres carrés.

2 Variance et écart-type

2.1 PRÉSENTATION

L'écart-type ou écart quadratique moyen est de loin l'indicateur de dispersion le plus utilisé. L'introduction en 1893 de son nom anglais *standard deviation* est due à Karl Pearson, mathématicien, statisticien et philosophe. La variance, qui est le carré de l'écart-type, a été introduite en statistique par le statisticien et généticien anglais Ronald Fisher.

Définitions

L'**écart-type**, noté σ_x , est la racine carrée de la variance.

Dans le cas de n observations, la variance est donnée par :

$$\begin{cases} V(x) = \sigma_x^2 = \frac{1}{n} \sum (x_i - \bar{x})^2 \\ \sigma(x) = \sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2} \end{cases}$$

Dans le cas de n observations, ordonnées dans un tableau statistique $(x_i ; n_i)$, présentant r modalités :

$$\begin{cases} V(x) = \sigma_x^2 = \frac{1}{n} \sum_{i=1}^{i=r} n_i (x_i - \bar{x})^2 \\ \sigma(x) = \sqrt{\frac{1}{n} \sum_{i=1}^{i=r} n_i (x_i - \bar{x})^2} \end{cases}$$

La **variance** (ou fluctuation) est la moyenne arithmétique des carrés des écarts à la moyenne. Elle se note $V(x)$.

L'écart-type peut également se définir comme la moyenne quadratique des écarts à la moyenne.

Exemple 3.2

Calculs de variance et d'écart-type

La série suivante donne le salaire minimal de croissance pour 169 heures de travail dans vingt pays d'Europe en 2006. La valeur du SMIC est indiquée entre parenthèses :

Belgique (1 234) ; Bulgarie (81,8) ; République tchèque (261,3) ; Estonie (191,7) ; Irlande (1 293) ; Grèce (667,7) ; Espagne (631) ; France (1 218) ; Lettonie (129,2) ; Lituanie (159,3) ; Luxembourg (1 503) ; Hongrie (247) ; Malte (580) ; Pays-Bas (1 273) ; Pologne (233,5) ; Portugal (450) ; Roumanie (90,2) ; Slovénie (511,9) ; Slovaquie (183,2) ; Royaume-Uni (1269).

Source : Eurostat, 2006

Calculons la variance et l'écart-type à l'aide d'Excel (voir figure 3.2).

Figure 3.2

Calcul des $(x_i - \bar{x})^2$ sous Excel.

	A	B	C
1	Pays	x_i	$n_i (x_i - \bar{x})^2$
2	Belgique	1 234,00	388 889,43
3	Bulgarie	81,80	279 407,39
4	République tchèque	261,30	121 863,83
5	Estonie	191,70	175 301,32
6	Irlande	1 293,00	465 956,41
7	Grèce	667,70	3 284,44
8	Espagne	631,00	424,77
9	France	1 218,00	369 189,91
10	Lettonie	129,20	231 543,82
11	Lituanie	159,30	203 482,19
12	Luxembourg	1 503,00	796 752,61
13	Hongrie	247,00	132 052,29
14	Malte	580,00	923,55
15	Pays-Bas	1 273,00	439 052,01
16	Pologne	233,50	142 046,07
17	Portugal	450,00	25 724,95
18	Roumanie	90,20	270 597,64
19	Slovénie	511,90	9 700,28
20	Slovaquie	183,20	182 491,30
21	Royaume-Uni	1 269,00	433 767,13
22	Somme	12 207,80	4 672 451,34

Le calcul de la moyenne donne $\bar{x} = \frac{1}{20} \sum_{i=1}^{20} x_i = \frac{12\,207,8}{20} = 610,39$. De là, après calcul de chacun des écarts à cette moyenne, et leur élévation au carré, $V(x) = \frac{1}{20} \sum_{i=1}^{20} (x_i - \bar{x})^2 = \frac{4\,672\,451,34}{20} = 233\,622,57$. La variance de la valeur du SMIC des différents pays européens est de 233 622,57. D'où l'écart-type $\sigma_x = \sqrt{V(x)} = \sqrt{233\,622,57} = 483,35$ €.

Afin de faciliter les différentes étapes de calcul de la variance, il est possible d'utiliser la formule développée de la variance. Cette formule est issue du théorème de Koenig.

Définitions

Formules développées de la variance :

- Cas de n observations : $V(x) = \left(\frac{1}{n} \sum_{i=1}^n x_i^2\right) - \bar{x}^2$.
- Cas d'un tableau statistique avec r modalités : $V(x) = \left(\frac{1}{n} \sum_{i=1}^r n_i x_i^2\right) - \bar{x}^2$.

Démonstration (dans le cas de n observations, ordonnées dans un tableau statistique $(x_i ; n_i)$, comprenant r modalités) :

$$V(x) = \frac{1}{n} \sum_{i=1}^r n_i (x_i - \bar{x})^2$$

$$V(x) = \frac{1}{n} \sum_{i=1}^r n_i (x_i^2 - 2x_i \bar{x} + \bar{x}^2)$$

$$V(x) = \frac{1}{n} \sum_{i=1}^r n_i x_i^2 - 2\bar{x} \frac{1}{n} \sum_{i=1}^r n_i x_i + \bar{x}^2 \frac{1}{n} \sum_{i=1}^r n_i$$

$$V(x) = \frac{1}{n} \sum_{i=1}^r n_i x_i^2 - 2\bar{x}\bar{x} + \bar{x}^2$$

$$V(x) = \frac{1}{n} \sum_{i=1}^r n_i x_i^2 - \bar{x}^2$$

Par cette formule, la variance est égale à la moyenne des x_i au carré moins le carré de la moyenne des x_i . Le procédé mnémotechnique suivant est parfois utilisé : $V(x) = MC - CM$, soit **la variance est égale à la Moyenne des Carrés moins le Carré de la Moyenne**.

Exemple 3.3

Calcul de la variance par la formule développée

Reprenons les données de l'exemple 3.2 et calculons la variance avec la formule développée, à l'aide de la calculatrice : saisissez les valeurs du SMIC dans la colonne L1 du tableau (voir figure 3.3) en appuyant sur la touche **STAT** puis en éditant le tableau par appui sur la touche **↓**.

Figure 3.3

Extrait de la saisie du tableau de données avec la calculatrice.

L1	L2	L3	1
1234	-----	-----	
81.8			
261.3			
191.7			
1293			
562.7			
730			
L1(7)=631			

Lorsque les vingt valeurs sont saisies, appuyez sur la touche **STAT**, puis, dans le menu CALC, appelez la fonction 1-Var Stats. Validez avec **ENTER**. Les résultats présentés figure 3.4 s'affichent.

Figure 3.4

Résultats de l'analyse statistique effectuée avec la calculatrice.

```
1-Var Stats
x̄=610.39
Σx=12207.8
Σx²=12123970.4
Sx=495.9016954
σx=483.345184
↓n=20
```

Lecture des résultats : on notera que la calculatrice désigne par $\sum x$ et $\sum x^2$ les sommes des valeurs ou de leurs carrés, que l'on ait affaire à n observations brutes ou à n observations ordonnées dans un tableau statistique. Par défaut, comme dans cet exemple, les n_i sont pris égaux à 1. Enfin, l'écart-type est $\sigma_x = 483,35$. Il ne faut pas le confondre avec $S_x = 495,9$ appelé écart-type d'échantillon (supérieur à σ_x), qui permet d'estimer l'écart-type d'une population à partir d'un échantillon de cette population (voir P. Roger, chapitre 5).

À partir de ces résultats il est possible de calculer directement la variance :

$$V(x) = \frac{1}{20} \sum_{i=1}^{20} x_i^2 - \bar{x}^2 = \frac{1}{20} \times 12\,123\,970,4 - 610,39^2 = 233\,622,57, \text{ soit la même valeur que}$$

par la formule classique de la variance, conformément à la démonstration du théorème de Koenig. Ce résultat peut également être obtenu en élevant l'écart-type au carré :

$$V(x) = \sigma_x^2 = 483,34^2 = 233\,622,57.$$

2.2 CAS D'UN CARACTÈRE CONTINU

Dans le cas d'un caractère continu, le calcul se fait en remplaçant chaque classe par sa valeur centrale, x_i . Cette méthode, dite du centre de classe, tend à augmenter l'écart-type, notamment dans le cas d'une distribution unimodale où les effectifs diminuent rapidement quand on s'écarte de la moyenne (distribution proche de la distribution normale). Une correction empirique, dite correction de Sheppard, est parfois utilisée.

2.3 PROPRIÉTÉS DE CALCUL DE LA VARIANCE ET DE L'ÉCART-TYPE

La variance et l'écart-type ne sont pas linéaires comme la moyenne, mais possèdent des propriétés très importantes.

Propriétés

$V(x + a) = V(x)$, donc $\sigma(x + a) = \sigma(x)$: ajouter une constante ne change pas la dispersion.

$V(ax) = a^2 V(x)$, donc $\sigma(ax) = |a| \times \sigma(x)$: multiplier la série par un réel positif multiplie la variance par le carré de ce nombre et l'écart-type par la valeur absolue de ce nombre.

Démonstrations dans le cas de n observations, ordonnées dans un tableau statistique $(x_i ; n_i)$:

$$V(x+a) = \frac{1}{n} \sum_{i=1}^r n_i \left[(x_i + a) - (\overline{x+a}) \right]^2$$

$$V(x+a) = \frac{1}{n} \sum_{i=1}^r n_i (x_i + a - \bar{x} - a)^2, \text{ avec la propriété de la moyenne } (\overline{x+a}) = \bar{x} + a$$

$$V(x+a) = \frac{1}{n} \sum_{i=1}^r n_i (x_i - \bar{x})^2$$

Soit $V(x+a) = V(x)$

$$V(ax) = \frac{1}{n} \sum_{i=1}^r n_i (ax_i)^2 - (\overline{ax})^2$$

$$V(ax) = a^2 \frac{1}{n} \sum_{i=1}^r n_i x_i^2 - a^2 \bar{x}^2, \text{ avec la propriété de la moyenne } (\overline{ax}) = a\bar{x}$$

$$V(ax) = a^2 \left(\frac{1}{n} \sum_{i=1}^r n_i x_i^2 - \bar{x}^2 \right)$$

Soit $V(ax) = a^2 V(x)$

Exemple 3.4

Applications des propriétés de la variance

Supposons que, dans une entreprise, le salaire moyen soit de 2 500 € avec un écart-type de 500 €.

- **Ajout d'une constante** : si tous les salaires augmentent de 200 €, la moyenne augmente également de 200 €, mais l'écart-type reste constant. Autrement dit, la dispersion des salaires sera toujours mesurée par un écart-type de 500 € autour du salaire moyen de 2 700 €.
- **Multipliation par une constante** : si tous les salaires augmentent de 5 %, le salaire moyen sera de $2500 \times 1,05 = 2625$ € et l'écart-type deviendra : $500 \times 1,05 = 525$ €.

Focus 3.1

L'écart-type

- L'écart-type est conforme à trois des conditions de Yule : il est défini de façon rigoureuse, il dépend de toutes les valeurs de la série et se prête bien aux calculs algébriques. Il a le défaut d'être sensible aux valeurs aberrantes, mais cette influence est limitée, les écarts exceptionnels étant pondérés par des effectifs faibles.
- On notera que l'écart-type, qui représente l'écart moyen d'une unité statistique à la moyenne, s'exprime dans les mêmes unités que la variable, ce qui n'est pas le cas de la variance (si la variable est une longueur exprimée en centimètres, la variance est exprimée en centimètres carrés).
- Population et échantillon : dans le cadre de la statistique inférentielle, on cherche à préciser les paramètres d'une population à partir d'un échantillon ; on rappelle (voir

exemple 3.4) que la calculatrice donne deux paramètres notés respectivement σ_x et S_x : σ_x désigne l'écart-type calculé sur les données considérées comme constituant la population et S_x une estimation ponctuelle de l'écart-type de la population, obtenue à partir d'un échantillon ($S_x \geq \sigma_x$).

- Additivité des variances : en général, la variance ne possède pas la propriété d'additivité. « Les variances ne s'additionnent que si les éléments constituant la somme ou la différence sont prélevés au hasard » (voir A. Liorzou). On dit alors que les variables sont indépendantes, et dans ce cas on a alors : x, y étant des variables quantitatives indépendantes et z leur somme, $V(z) = V(x) + V(y)$, ce qui donne pour les écarts-types une relation de Pythagore : $\sigma_z^2 = \sigma_x^2 + \sigma_y^2$ soit $\sigma_z = \sqrt{\sigma_x^2 + \sigma_y^2}$.
- L'écart absolu moyen est toujours inférieur ou égal à l'écart-type.

2.4 LE COEFFICIENT DE VARIATION

La comparaison directe de deux écarts-types peut donner une impression fautive concernant la dispersion des deux séries dont les valeurs des moyennes sont différentes. De plus, l'écart-type dépend de l'unité choisie. C'est pourquoi le coefficient de variation, qui mesure la dispersion relative à la moyenne, est utilisé pour comparer la dispersion de plusieurs séries.

Définition

Le **coefficient de variation** est le rapport noté $CV(x)$ et défini par : $CV(x) = \frac{\sigma_x}{\bar{x}}$; ce coefficient s'exprime en pourcentage de la moyenne.

Exemple 3.5

Écart-type et coefficient de variation

Considérons qu'à la suite d'une étude statistique portant sur le poids x des voyageurs et sur celui y des bagages, une compagnie aérienne ait obtenu les résultats suivants :

Paramètres	x	y
Moyenne	70 kg	15 kg
Écart-type	8 kg	6 kg

Pour la série des voyageurs $CV(x) = \frac{8}{70} = 0,1143$, soit 11,43 %, et pour la série des bagages : $CV(y) = \frac{6}{15} = 0,40$, soit 40 %.

Alors que l'écart-type de la série des voyageurs est plus grand que celui des bagages ($\sigma_x > \sigma_y$), la série des poids des bagages est plus dispersée que celle des poids des voyageurs, car $CV(y) > CV(x)$.

Le coefficient de variation est un nombre sans dimension, indépendant de l'unité de mesure ; il permet de mesurer la dispersion de séries exprimées en unités ou ordres de grandeur différents. Il mesure l'homogénéité des données.

Conclusion

Ce chapitre nous a enseigné que les valeurs centrales ne suffisent jamais à décrire une série statistique et que les paramètres de dispersion sont incontournables pour appréhender la structure interne de la série.

On notera le rôle prépondérant de la variance et de l'écart-type et on s'attachera à retenir leurs propriétés algébriques.

On retiendra que le coefficient de variation et la boîte à moustaches sont des outils extrêmement précieux dans le cadre de la comparaison des séries.

Enfin, ces paramètres vont nous permettre d'aller plus loin et de nous intéresser à la forme des distributions et notamment à la plus célèbre des lois de probabilité, la loi normale.

Les caractéristiques de forme et de concentration

1 La courbe de la loi normale

Nous avons vu que, selon son caractère discret ou continu, une série statistique peut être représentée par un diagramme en bâtons ou un histogramme des fréquences que l'on complète en général par le tracé du polygone des fréquences. Il faut garder à l'esprit que l'histogramme des fréquences est un bon estimateur de la densité et qu'en lissant le polygone des fréquences on peut représenter la série statistique par une distribution continue. La loi normale, également appelée loi de Laplace-Gauss, est le modèle fondamental des distributions continues.

La loi normale représente la distribution des valeurs d'une grandeur soumise à l'influence d'un grand nombre de facteurs indépendants les uns des autres, chacun exerçant des actions de faible intensité dont les effets tendent à se compenser.

1.1 PRÉSENTATION DE LA LOI NORMALE

De nombreux caractères quantitatifs du monde réel suivent une loi normale : les tailles des individus, les poids, la pression sanguine, les notes à un examen, etc.

Quand on désire mesurer une grandeur, par exemple une longueur, dont la vraie valeur est L , on opère n mesures, $x_1, x_2, \dots, x_n$, et la variable X dont les modalités sont les $(x_i - L)$, représente l'erreur commise dans la mesure de L . Cette variable suit une loi normale.

Aussi cette distribution est-elle souvent appelée « loi des erreurs », parce que les erreurs aléatoires dans les résultats de mesures sont souvent normalement distribuées.

Définitions

La **loi normale** est entièrement déterminée par deux paramètres : sa moyenne (m) et son écart-type (σ).

La **loi normale centrée réduite** constitue le modèle de référence ; sa moyenne est 0 (centrée) et son écart-type 1 (réduite). Sa densité est donnée par : $f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$ et sa représentation graphique est la célèbre courbe en cloche (voir figure 4.1). On dit que X suit la loi $N(0 ; 1)$.

Si une variable X suit une loi normale de paramètres m et σ , notée $N(m ; \sigma)$, alors $Z = \frac{X - m}{\sigma}$ suit la loi normale centrée réduite de paramètres 0 et 1. On dit que l'on a standardisé X .


La courbe représentant la distribution $N(0 ; 1)$ est symétrique, avec : $\bar{x} = Mo = Me = 0$. Elle est « normalement aplatie ».

Avec $\bar{x} = 0$ et $\sigma = 1$, l'intervalle $]\bar{x} - \sigma ; \bar{x} + \sigma[$ qui correspond à $]-1 ; 1[$ représente 68,26 % des observations et l'intervalle $]\bar{x} - 2\sigma ; \bar{x} + 2\sigma[$ qui correspond à $]-2 ; 2[$ représente 95,44 % des observations.

Les deux quartiles Q_1 et Q_3 sont opposés et valent respectivement $-0,67$ et $0,67$.

Figure 4.1

La courbe en cloche de la loi normale centrée réduite.



2 Les caractéristiques de forme

2.1 L'ASYMÉTRIE (SKEWNESS)


Une distribution est dite symétrique, comme la loi normale, si les valeurs observées se répartissent de façon uniforme autour des trois valeurs centrales alors égales : la moyenne, le mode et la médiane.

Pour mesurer l'asymétrie d'une distribution, on dispose de différents coefficients. Le but est de comparer les formes de plusieurs distributions, ces comparaisons n'ayant de sens que si elles sont faites à partir des mêmes coefficients appliqués aux différentes distributions.

La figure 4.3 montre les trois formes de symétrie et asymétrie possibles.

Figure 4.3

Symétrie et asymétrie.



Le coefficient de Yule et Kendall

Le coefficient de Yule et Kendall – couramment appelé coefficient de Yule – compare l'étalement de la courbe à droite et à gauche de la médiane.

Définition

Le **coefficient de Yule** sert à mesurer l'asymétrie de la distribution en tenant compte des positions relatives des quartiles par rapport à la médiane. Il est défini par :

$$C_Y = \frac{Q_1 + Q_3 - 2Me}{Q_3 - Q_1}, \text{ ou de manière équivalente par } C_Y = \frac{Q_1 - Me + Q_3 - Me}{Q_3 - Q_1}.$$

Ce coefficient permet de localiser la médiane dans la boîte à moustaches, par rapport au milieu du segment formé par Q_1 et Q_3 .

Dans le cas d'une distribution symétrique, comme la loi normale, ce coefficient est nul, les quartiles Q_1 et Q_3 étant équidistants de la médiane.

Ce coefficient C_Y est indépendant de l'unité de mesure. En outre, il est toujours compris entre -1 et 1 , car la médiane est située entre Q_1 et Q_3 .

- Si $C_Y = 0$, la distribution est symétrique.
- Si $C_Y > 0$, la distribution est étalée à droite.
- Si $C_Y < 0$, la distribution est étalée à gauche.

Les coefficients de Pearson

Les coefficients de Pearson étudient l'étalement de la courbe à partir des valeurs de la moyenne, du mode et de l'écart-type.

Définition

Le **coefficient S de Pearson** mesure l'asymétrie d'une distribution par une comparaison entre les valeurs de la moyenne et du mode. Il se note $S = \frac{\bar{x} - Mo}{\sigma}$. Il s'agit d'un coefficient sans dimension.

L'interprétation de la valeur du S de Pearson se fait comme suit :

- Si $S = 0$, la distribution est symétrique.
- Si $S > 0$, la distribution est étalée à droite.
- Si $S < 0$, la distribution est étalée à gauche.

Définition

Le **coefficient d'asymétrie β_1 de Pearson** est défini par : $\beta_1 = \frac{\mu_3^2}{\mu_2^3}$.

μ_3 désigne le moment centré d'ordre 3, soit $\mu_3 = \frac{1}{n} \sum_{i=1}^r n_i (x_i - \bar{x})^3$.

μ_2 est le moment centré d'ordre 2, c'est-à-dire la variance.

L'interprétation de la valeur du β_1 de Pearson se fait comme suit :

- Si β_1 est proche de 0, la distribution est approximativement symétrique.
- Si $\beta_1 > 0$, elle est étalée à droite pour $\mu_3 > 0$ et étalée à gauche pour $\mu_3 < 0$.

Le coefficient de Fisher

Définition

Le **coefficient d'asymétrie γ_1 de Fisher** est défini par : $\gamma_1 = \frac{\mu_3}{\sigma^3}$.

μ_3 désigne le moment centré d'ordre 3, soit $\mu_3 = \frac{1}{n} \sum_{i=1}^r n_i (x_i - \bar{x})^3$.

Ce coefficient, sans dimension, a le même signe que μ_3 .

L'interprétation de la valeur du γ_1 de Fisher se fait comme suit :

- Si γ_1 est proche de 0, la distribution est approximativement symétrique.
- Si $\gamma_1 > 0$, la distribution est étalée à droite.
- si $\gamma_1 < 0$, la distribution est étalée à gauche.

Exemple 4.1

Calculs des coefficients d'asymétrie

Le tableau suivant donne une estimation de la répartition par âges des assurés obligatoires de plus de 20 ans et de moins de 60 ans, en France, en 1921 :

Âge (années)	Effectif (milliers)
[20 ; 25[	1 275
[25 ; 30[	1 080
[30 ; 35[	890
[35 ; 40[	805
[40 ; 45[	745
[45 ; 50[	675
[50 ; 55[	610
[55 ; 60[	505

Source : Bureau international du travail, 1921

Calculons les différents coefficients d'asymétrie à l'aide d'Excel (voir figure 4.4).

Figure 4.4

Calcul des coefficients d'asymétrie sous Excel.

	A	B	C	D	E	F	G	H	I
1	a_i	b_i	n_i	f_i	x_i	$n_i \text{ Cum}$	$n_i x_i$	$n_i x_i^2$	$n_i (x_i - \bar{x})^3$
2	20	25	1 275	0,1936	22,5	1 275	28 687,5	645 468,75	-3 723 655,35
3	25	30	1 080	0,1640	27,5	2 355	29 700,0	816 750,00	-866 983,20
4	30	35	890	0,1352	32,5	3 245	28 925,0	940 062,50	-70 458,03
5	35	40	805	0,1222	37,5	4 050	30 187,5	1 132 031,25	283,46
6	40	45	745	0,1131	42,5	4 795	31 662,5	1 345 656,25	138 415,88
7	45	50	675	0,1025	47,5	5 470	32 062,5	1 522 968,75	828 330,75
8	50	55	610	0,0926	52,5	6 080	32 025,0	1 681 312,50	2 363 410,09
9	55	60	505	0,0767	57,5	6 585	29 037,5	1 669 656,25	4 483 213,97
10	Somme		6 585	1,0000			242 287,5	9 753 906,25	3 152 657,56

Le calcul de la moyenne donne $\bar{x} = \frac{1}{6\,585} \sum_{i=1}^8 n_i x_i = \frac{242\,287,5}{6\,585} = 36,79$.

La variance, ou moment centré d'ordre 2, est :

$$V(x) = \frac{1}{6\,585} \sum_{i=1}^8 n_i x_i^2 - \bar{x}^2 = \frac{1}{6\,585} \times 9\,753\,906,25 - 36,79^2 = 127,44, \text{ et l'écart-type :}$$

$$\sigma_x = \sqrt{V(x)} = \sqrt{127,44} = 11,29.$$

Le moment centré d'ordre 3 est $\mu_3 = \frac{1}{6\,585} \sum_{i=1}^8 n_i (x_i - \bar{x})^3 = \frac{3\,152\,657,56}{6\,585} = 478,76$.

À partir de la colonne des n_i cumulés croissants et par interpolation linéaire, on obtient $Q_1 = 26,72$; $Me = 35,30$ et $Q_3 = 46,06$.

Le mode est égale à $Mo = \frac{k_2 x_1 + k_1 x_2}{k_1 + k_2} = \frac{195 \times 20 + 1275 \times 25}{1275 + 195}$, soit $Mo = 24,33$.

Suite à ces calculs, nous pouvons déterminer l'ensemble des coefficients d'asymétrie.

$$C_y = \frac{26,72 + 46,06 - 2 \times 35,3}{46,06 - 26,72}, \text{ soit } C_y = \mathbf{0,11}; \quad S = \frac{36,79 - 24,33}{11,29}, \text{ soit } S = \mathbf{1,10};$$

$$\beta_1 = \frac{478,76^2}{127,44^3}, \text{ soit } \beta_1 = \mathbf{0,11}; \quad \gamma_1 = \frac{478,76}{11,29^3}, \text{ soit } \gamma_1 = \mathbf{0,33}.$$


Les coefficients mettent en évidence une distribution asymétrique étalée à droite, ce que confirme la réalisation de l'histogramme.

2.2 L'APLATISSEMENT (KURTOSIS)

L'aplatissement d'une distribution est un indicateur de la dispersion autour des valeurs centrales. Plus la dispersion est grande, plus la courbe sera « plate ». On définira deux coefficients, celui de Pearson et celui de Fisher, ces coefficients étant des coefficients de comparaison par rapport à la distribution normale.

La figure 4.5 montre les trois formes d'aplatissement possibles.

Figure 4.5
Aplatissement.



Le coefficient de Pearson

Définition

Le **coefficient β_2 de Pearson** sert à mesurer l'aplatissement. Il est défini par $\beta_2 = \frac{\mu_4}{\mu_2^2} = \frac{\mu_4}{\sigma^4}$.

Il s'agit d'un coefficient sans dimension. $\beta_2 \geq 1$ et dans le cas d'une distribution normale $\beta_2 = 3$.

Interprétation :

- Si $\beta_2 < 3$, la courbe est dite platycurtique, c'est-à-dire plus plate que la loi normale.
- Si $\beta_2 = 3$, la courbe est proche de la courbe normale.
- Si $\beta_2 > 3$, la courbe est leptocurtique, c'est-à-dire plus pointue que la loi normale.

Le coefficient de Fisher

Définition

Le **coefficient γ_2 de Fisher** sert à mesurer l'aplatissement. Il est défini par

$$\gamma_2 = \frac{\mu_4}{\mu_2^2} - 3 = \frac{\mu_4}{\sigma^4} - 3. \text{ Ou encore, de manière équivalente, } \gamma_2 = \beta_2 - 3.$$

La constante 3 est choisie de façon à obtenir un coefficient nul pour une distribution normale ; par ailleurs, $\gamma_2 \geq -2$.

Interprétation :

- Si $\gamma_2 < 0$, la courbe est dite platycurtique, c'est-à-dire plus plate que la loi normale.
- Si $\gamma_2 = 0$, la courbe est proche de la courbe normale.
- Si $\gamma_2 > 0$, la courbe est leptocurtique, c'est-à-dire plus pointue que la loi normale.

On notera que γ_2 mesure l'importance des « queues de distribution ».

Conclusion

Ce chapitre complète la première démarche qui a consisté à ordonner les observations et à les résumer à l'aide de graphiques et de paramètres mettant en évidence la tendance centrale et la dispersion.

Nous nous sommes attachés à caractériser la forme de la distribution et, ce faisant, à ouvrir la porte à une interprétation plus approfondie, en introduisant la distribution normale, démarche que nous compléterons avec d'autres lois de probabilité.

Les séries bivariées

1 Présentation des données

Il existe deux façons de présenter une série bivariée :

- les tableaux simples, composés des observations en ligne et des variables en colonne ;
- les tableaux de contingence, qui croisent les modalités des deux variables.

1.1 DONNÉES EXHAUSTIVES : TABLEAUX SIMPLES

Les tableaux simples des séries bivariées sont constitués :

- des observations en ligne ;
- des deux variables en colonne.

Ainsi, chaque ligne comporte l'identifiant de l'observation dans la première colonne et les modalités observées pour chacune des deux variables dans les deux colonnes suivantes.

Exemple 5.1

Série bivariée et tableau simple

Le tableau suivant indique, pour chacune des trois académies d'Île-de-France, le nombre de licenciés en 2005 et le nombre de licenciés poursuivant leurs études à l'université, en 2006. Il recense ainsi la poursuite des études à l'université après la licence.

Académie	Nombre de licenciés (2005)	Licenciés à l'université (2006)
Paris	14 150	11 271
Créteil	7 759	5 150
Versailles	7 254	5 107
Total	29 163	21 528

Source : ministère de l'Éducation nationale, 2006

Cette série double, ou bivariée, comporte trois modalités. Si l'on note X le nombre de licenciés en 2005 et Y le nombre de licenciés poursuivant leurs études à l'université en 2006, Créteil est représentée par la modalité $(x_2; y_2) = (7\,759; 5\,150)$. En exploitant chaque variable une par une, il est possible de calculer tous les indicateurs des séries univariées, comme les moyennes. Ainsi, $\bar{x} = \frac{29\,163}{3} = 9\,721$; le nombre moyen de licenciés est de 9 721 étudiants par académie. De même, $\bar{y} = \frac{21\,528}{3} = 7\,176$; le nombre moyen de licenciés poursuivant leurs études à l'université est de 7 176 étudiants par académie.

On représente cette série en plaçant dans un repère les trois points de coordonnées $(x_i; y_i)$ pour i entier variant de 1 à 3 ; cette représentation s'appelle un nuage de points. Le point G de coordonnées respectives $\bar{x}$ et $\bar{y}$ est appelé point moyen du nuage.

Dans une série double de ce type, les effectifs de chaque modalité sont égaux à 1 et ne sont pas mentionnés. Il est possible de calculer sur les séries marginales les moyennes et tous les paramètres nécessaires à l'étude de la série bivariée, comme les variances.

Un nouveau paramètre, la covariance, sera introduit à la section 2.4.

1.2 LE TABLEAU CROISÉ OU TABLEAU DE CONTINGENCE

Les tableaux croisés ou tableaux de contingence sont les tableaux obtenus quand on étudie une population sous l'angle de deux caractères que l'on croise. Dans le cas particulier où ces caractères ont chacun deux modalités (cas binaire), on obtient le cas particulier des tableaux 2×2 .

Côté « technique », les tableaux à double entrée ne sont pas différents de ce que les mathématiciens appellent matrices, tableaux de nombres à n lignes et p colonnes et dont nous noterons n_{ij} le terme situé à l'intersection de la ligne i et de la colonne j .

Une des caractéristiques des tableaux de contingence, qui sont très présents dans l'analyse de données, est d'attribuer un sens aux « marges », c'est-à-dire à une colonne supplémentaire à droite et à une ligne supplémentaire en bas, qui indiquent le nombre d'individus possédant une des modalités de l'un des deux caractères (ce que l'on appelle le tri à plat de ce caractère).

Présentation des effectifs du tableau de contingence

Soit respectivement p et q les nombres de modalités des caractères X et Y .

- Les modalités du caractère X se notent x_i avec $i = \{1, 2, \dots, p\}$.
- Les modalités du caractère Y se notent y_j avec $j = \{1, 2, \dots, q\}$.

Définitions

L'**effectif partiel** de la modalité (x_i, y_j) est le nombre d'observations présentant simultanément les deux modalités x_i et y_j . Il se note n_{ij} .

L'**effectif marginal** de la modalité x_i se note n_{i+} , ou encore $n_{i\cdot}$, tel que : $n_{i+} = \sum_{j=1}^q n_{ij}$. Cet effectif désigne la somme des effectifs de la ligne i . La distribution des effectifs marginaux de X s'appelle distribution marginale de X .

De même, $n_{+j} = \sum_{i=1}^p n_{ij}$, ou encore $n_{\cdot j}$, est l'effectif marginal de la modalité y_j . Il désigne la somme des effectifs de la colonne j . La distribution des effectifs marginaux de Y s'appelle distribution marginale de Y .

L'**effectif total** de la série double est la somme des effectifs marginaux de la série X (ou Y).

Il est noté n_{++} , $n_{\cdot\cdot}$ ou simplement n , avec : $n_{++} = \sum_{j=1}^q n_{+j} = \sum_{i=1}^p n_{i+} = \sum_{j=1}^q \sum_{i=1}^p n_{ij} = \sum_{i=1}^p \sum_{j=1}^q n_{ij}$.

En adoptant l'ensemble de ces notations, le tableau de contingence contenant les effectifs se présente de la manière suivante :

- Les modalités x_i de X apparaissent dans la première colonne.
- Les modalités y_j de Y apparaissent sur la première ligne.
- L'effectif partiel n_{ij} de la modalité (x_i, y_j) est inscrit au croisement de la ligne i et de la colonne j .
- L'effectif marginal n_{i+} de X est reporté dans la dernière colonne du tableau. L'effectif marginal n_{+j} de Y est reporté sur la dernière ligne du tableau. La dernière ligne et la dernière colonne du tableau de contingence s'appellent les marges et contiennent la distribution marginale de X et de Y. Elles représentent les effectifs des séries simples X et Y.
- L'effectif total n_{++} est indiqué au croisement des deux distributions marginales de X et de Y.

D'où la présentation suivante du tableau de contingence :

X \ Y	y_1	y_2	...	y_j	...	y_q	n_{i+}
x_1	n_{11}	n_{12}	...	n_{1j}	...	n_{1q}	n_{1+}
x_2	n_{21}	n_{22}	...	n_{2j}	...	n_{2q}	n_{2+}
...	...	...	...	...	...	...	...
x_i	n_{i1}	n_{i2}	...	n_{ij}	...	n_{iq}	n_{i+}
...	...	...	...	...	...	...	...
x_p	n_{p1}	n_{p2}	...	n_{pj}	...	n_{pq}	n_{p+}
n_{+j}	n_{+1}	n_{+2}	...	n_{+j}	...	n_{+q}	n_{++}

Exemple 5.2

Un tableau de contingence 2×2

Certaines entreprises mettent en avant auprès des consommateurs des engagements de « citoyenneté » : par exemple, fabriquer sans générer de pollution, ne pas avoir recours au travail des enfants, etc. Le tableau ci-après donne le résultat sur un échantillon constitué sur la base des résultats d'une enquête du Credoc de l'année 2006, en réponse à la question : « D'une façon générale, tenez-vous compte de ces éléments lorsque vous achetez un produit ? »

Sexe \ Réponse	Oui (O)	Non (N)	Total
Masculin (M)	290	410	700
Féminin (F)	141	159	300
Total	431	569	1 000

Source : Credoc, 2006

Ce tableau comporte deux caractères qualitatifs :

- X, le sexe, avec les deux modalités $x_1 = M$ et $x_2 = F$;

- Y, la réponse à la question de citoyenneté, avec les deux modalités $y_1 = O$ et $y_2 = N$.

L'effectif total est de 1 000 et il y a quatre modalités. Par exemple, le couple $(x_1 ; y_2) = (M ; N)$ a un effectif situé au croisement de la première ligne et de la deuxième colonne et noté $n_{12} = 410$.

Les sommes des effectifs en ligne sont indiqués dans la dernière colonne et les sommes des effectifs en colonne sur la deuxième ligne du tableau.

- Par exemple, la somme des effectifs de la deuxième ligne, $n_{2+} = 300$ est indiquée dans la dernière colonne, sur la dernière ligne. Il s'agit du nombre total de femmes, également appelé effectif marginal de la modalité Féminin de la variable Sexe.
- De même, la somme des effectifs de la première colonne $n_{+1} = 431$ est donnée sur la dernière ligne. Il s'agit de l'effectif de la modalité Oui, sans distinction de sexe, également appelé effectif marginal de la modalité Oui de la variable Réponse.

Le détail des effectifs de cette série est donné dans la présentation générale suivante :

$X \setminus Y$	$y_1 = O$	$y_2 = N$	n_{i+}
$x_1 = M$	$n_{11} = 290$	$n_{12} = 410$	$n_{1+} = 700$
$x_2 = F$	$n_{21} = 141$	$n_{22} = 159$	$n_{2+} = 300$
n_{+j}	$n_{+1} = 431$	$n_{+2} = 569$	$n_{++} = 1000$

Les fréquences des tableaux de contingence

À partir du tableau de contingence composé des effectifs, il est possible de calculer les fréquences (fréquences relatives). Il existe trois types de fréquences :

- les fréquences partielles ;
- les fréquences marginales ;
- les fréquences conditionnelles.

Définitions

La **fréquence partielle** de la modalité (x_i, y_j) est notée f_{ij} et est définie par $f_{ij} = \frac{n_{ij}}{n_{++}}$. Il est

clair que $\sum_{j=1}^p \sum_{i=1}^q f_{ij} = 1$. On retrouve le concept d'intersection, ces individus appartenant à la modalité x_i de X et à la modalité y_j de Y.

La **fréquence marginale** de la modalité x_i est notée f_{i+} et est définie par $f_{i+} = \frac{n_{i+}}{n_{++}}$. Il est

clair que $f_{i+} = \sum_{j=1}^p f_{ij}$.

De même, la fréquence marginale de la modalité y_j est notée f_{+j} et est définie par

$$f_{+j} = \frac{n_{+j}}{n_{++}} = \sum_{i=1}^q f_{ij}.$$

Exemple 5.3

Calcul des fréquences partielles et marginales sur tableau de contingence

Reprenons le tableau de contingence de l'exemple 5.2 ci-avant.

Il est possible de déterminer les fréquences partielles f_{ij} . Par exemple, $f_{12} = 410 / 1000 = 0,41$, so

it 41 % des individus de notre enquête sont des hommes et ont répondu non.

Il est également possible de déterminer les fréquences marginales f_{i+} ou f_{+j} . Par exemple, $f_{+1} = 431 / 1000 = 0,431$, soit 43,1 % des individus de l'enquête ont répondu oui.

Les séries marginales peuvent éventuellement être extraites. Par exemple, l'extraction de la série marginale du caractère X donne :

Sexe	n_{i+}
Masculin (M)	700
Féminin (F)	300
Total	1 000

Cette présentation pourra faciliter les calculs de fréquence, moyenne, variance et écart-type dans le cas des caractères quantitatifs. Par exemple, ici, les fréquences marginales du caractère Sexe sont aisément repérables : $f_{1+} = 0,70$ et $f_{2+} = 0,30$, soit 70 % d'hommes et 30 % de femmes.

Les fréquences conditionnelles nous permettent d'aborder la distribution conditionnelle. Cette distribution est à relier à la notion de probabilité conditionnelle, qui consiste à effectuer un changement de l'univers ou de la population étudiés (voir P. Roger, page 17). Cela revient à effectuer les calculs sur une sous-population présentant une modalité choisie au lieu de s'intéresser à la population entière.

Définitions

Distributions conditionnelles : Si le caractère Y possède q modalités, on peut définir q distributions conditionnelles de X sachant Y. Les effectifs de ces distributions sont représentés par chacune des colonnes du tableau de contingence. L'effectif total de la distribution conditionnelle de X sachant $Y = y_i$ étant alors n_{+i} .

De même, si le caractère X possède p modalités, on peut définir p distributions conditionnelles de Y sachant X. Les effectifs de ces distributions sont représentés par chacune des lignes du tableau de contingence. L'effectif total de la distribution conditionnelle de Y sachant $X = x_i$ étant alors n_{i+} .

Fréquences conditionnelles de X sachant Y : La fréquence conditionnelle de la modalité x_i sachant y_j est donnée par $f_{X=x_i/Y=y_j} = \frac{n_{ij}}{n_{+j}}$. Ainsi, $\sum_{i=1}^p f_{X=x_i/Y=y_j} = 1$. Elle est aussi notée $f_{i/+j}$.

Fréquences conditionnelles de Y sachant X : La fréquence conditionnelle de la modalité y_j sachant x_i est donnée par $f_{Y=y_j/X=x_i} = \frac{n_{ij}}{n_{i+}}$. Ainsi, $\sum_{j=1}^q f_{Y=y_j/X=x_i} = 1$. Elle est aussi notée $f_{j/i+}$.

Il existe une relation entre les fréquences conditionnelles et les fréquences partielles précédemment définies : $f_{ij} = f_{i+} \times f_{+j}$. Cette relation est similaire au théorème des probabilités composées qui indique que :

$$P((X = x_i) \cap (Y = y_j)) = P_{(Y=y_j)}(X = x_i) \times P(Y = y_j).$$

Exemple 5.4

Calcul des fréquences conditionnelles sur tableau de contingence : sexe et citoyenneté

Reprenons le tableau de contingence de l'exemple 5.2 ci-avant.

Au lieu de s'intéresser à la population entière, il est possible de s'intéresser à l'univers des femmes. L'univers de travail est alors la sous-population notée $\{X = x_2\}$. Elle est constituée des individus présentant la modalité F de la variable X.

Cherchons alors la proportion de réponses Oui, soit d'individus appartenant à la modalité y_1 de Y dans cette sous-population. Cette fréquence conditionnelle est notée indifféremment $f_{Y=y_1/X=x_2}$, $f_{j=1/i=2}$ ou $f_{1/2+}$ (on lit « f indice j = 1 sachant i = 2 » si les indices i et j ont été respectivement affectés aux modalités de X et de Y) et définie par :

$$f_{j=1/i=2} = \frac{n_{21}}{n_{2+}} = \frac{141}{300} = 0,47 ; \text{ ainsi, 47 \% des femmes ont répondu oui.}$$

Il est ainsi possible de calculer toutes les fréquences conditionnelles de X sachant Y.

$X \setminus Y$	$y_1 = O$	$y_2 = N$
$x_1 = M$	$f_{i=1/j=1} = 0,6729$	$f_{i=1/j=2} = 0,7206$
$x_2 = F$	$f_{i=2/j=1} = 0,3271$	$f_{i=2/j=2} = 0,2794$
f_{+j}	1	1

De même, il est possible de calculer toutes les fréquences conditionnelles de Y sachant X.

$X \setminus Y$	$y_1 = O$	$y_2 = N$	f_{i+}
$x_1 = M$	$f_{j=1/i=1} = 0,4143$	$f_{j=2/i=1} = 0,5857$	1
$x_2 = F$	$f_{j=1/i=2} = 0,47$	$f_{j=2/i=2} = 0,53$	1

2 Les caractéristiques des séries à deux caractères

Les fréquences, indicateurs qui se calculent dans le cadre des séries univariées, se calculent également sur des séries bivariées. Il en va de même pour les autres caractéristiques des séries statistiques que sont la moyenne, la variance et l'écart-type.

Ces caractéristiques peuvent être calculées sur des variables quantitatives, à partir :

- des distributions marginales : il s'agit de caractéristiques marginales ;
- des distributions conditionnelles : il s'agit de caractéristiques conditionnelles.

2.1 LES CARACTÉRISTIQUES MARGINALES

Les séries marginales sont des séries univariées. Les calculs des moyennes, variances et écarts-types marginaux se font donc de la façon habituelle, après extraction de la série marginale.

Définitions

Moyennes marginales : $\bar{x} = \frac{1}{n_{++}} \sum_{i=1}^p n_{i+} \times x_i = \frac{1}{n_{++}} \sum_{i=1}^p x_i \sum_{j=1}^q n_{ij}$ et de même

$$\bar{y} = \frac{1}{n_{++}} \sum_{j=1}^q n_{+j} \times y_j = \frac{1}{n_{++}} \sum_{j=1}^q y_j \sum_{i=1}^p n_{ij}.$$

Remarque : certains auteurs notent ces moyennes marginales respectivement : $\bar{\bar{x}}$ et $\bar{\bar{y}}$.

Variances marginales : $V(x) = \frac{1}{n_{++}} \sum_{i=1}^p n_{i+} (x_i - \bar{x})^2$, de formule développée

$$V(x) = \frac{1}{n_{++}} \sum_{i=1}^p n_{i+} x_i^2 - \bar{x}^2. \text{ De même, } V(y) = \frac{1}{n_{++}} \sum_{j=1}^q n_{+j} (y_j - \bar{y})^2 = \frac{1}{n_{++}} \sum_{j=1}^q n_{+j} y_j^2 - \bar{y}^2.$$

Écarts-types marginaux : Les écarts-types marginaux sont déduits des variances marginales, $\sigma(x) = \sqrt{V(x)}$ et $\sigma(y) = \sqrt{V(y)}$.

Exemple 5.5

Calcul des caractéristiques marginales

Soit un échantillon d'entreprises sur lequel sont observées les variables X, investissement annuel en milliers d'euros, et Y, chiffre d'affaires annuel en millions d'euros :

X \ Y	[10 ; 30[	[30 ; 50[	[50 ; 70[	Somme
[10 ; 30[	300	80	0	380
[30 ; 40[	70	200	50	320
[40 ; 50[	20	30	250	300
Somme	390	310	300	1 000

On extrait les séries marginales en utilisant les centres de classes. Les moyennes, variances et écarts-types marginaux sont ensuite calculés sur ces séries, comme dans le cas d'une série univariée ; la figure 5.1 donne la distribution marginale de X.

Figure 5.1

Calcul des caractéristiques marginales de X.

	A	B	C	D
1	x_i	n_{i+}	$n_{i+}x_i$	$n_{i+}x_i^2$
2	20	380	7 600	152 000
3	35	320	11 200	392 000
4	45	300	13 500	607 500
5	Somme	1 000	32 300	1 151 500

Ce qui donne : $\bar{x} = \frac{32\,300}{1\,000} = 32,3$; $V(x) = \frac{1\,151\,500}{1\,000} - (32,3)^2 = 108,21$ et $\sigma(x) = 10,4$.

En faisant de même pour la distribution marginale de Y, on obtient $\bar{y} = \frac{38\,200}{1\,000} = 38,2$;

$V(y) = \frac{1\,732\,000}{1\,000} - (38,2)^2 = 272,76$ et $\sigma(y) = 16,52$.

2.2 LES CARACTÉRISTIQUES CONDITIONNELLES

Comme les caractéristiques marginales, les calculs des moyennes, variances et écarts-types conditionnels se font donc de la façon habituelle, après extraction de la distribution conditionnelle concernée.

Définitions

Moyennes conditionnelles : Les moyennes conditionnelles de X sont les moyennes des distributions conditionnelles de X sachant Y. $\bar{x}_i = \sum_{j=1}^p (f_{j/i+}) \times x_i = \frac{1}{n_{+j}} \sum_{i=1}^p n_{ij} x_i$ est la moyenne conditionnelle de X sachant $Y = y_j$.

De même, les moyennes conditionnelles de Y sont les moyennes des distributions conditionnelles de Y sachant X. $\bar{y}_i = \sum_{j=1}^q (f_{j/i+}) \times y_j = \frac{1}{n_{i+}} \sum_{j=1}^q n_{ij} y_j$ est la moyenne conditionnelle de Y sachant $X = x_i$.

Variances conditionnelles : Les variances conditionnelles de X sont les variances des distributions conditionnelles de X sachant Y. La variance conditionnelle de X sachant $Y = y_j$ est notée $V_j(x) = \frac{1}{n_{+j}} \sum_{i=1}^p n_{ij} (x_i - \bar{x}_i)^2 = \frac{1}{n_{+j}} \sum_{i=1}^p n_{ij} x_i^2 - \bar{x}_i^2$.

De même, les variances conditionnelles de Y sont les variances des distributions conditionnelles de Y sachant X. La variance conditionnelle de Y sachant $X = x_i$ est notée $V_i(y) = \frac{1}{n_{i+}} \sum_{j=1}^q n_{ij} (y_j - \bar{y}_i)^2 = \frac{1}{n_{i+}} \sum_{j=1}^q n_{ij} y_j^2 - \bar{y}_i^2$.

Écarts-types conditionnels : Les écarts-types conditionnels sont déduits des variances conditionnelles, $\sigma(x) = \sqrt{V(x)}$ et $\sigma(y) = \sqrt{V(y)}$.

Exemple 5.6

Calcul des caractéristiques conditionnelles

Reprenons les données de l'exemple 5.5.

Extrayons la distribution conditionnelle de X sachant Y = 60. À partir de cette série extraite, assimilable à une série univariée, nous effectuons les étapes nécessaires aux calculs de la moyenne et de la variance (voir figure 5.2).

Figure 5.2

Distribution conditionnelle de X sachant Y = 60.

	A	B	C	D
1	x_i	n_{i3}	$n_{i3}x_i$	$n_{i3}x_i^2$
2	20	0	0	0
3	35	50	1 750	61 250
4	45	250	11 250	506 250
5	Somme	300	13 000	567 500

D'où les paramètres conditionnels : $\bar{x}_3 = \frac{13\,000}{300} = 43,33$;

$V_3(X) = \frac{567\,500}{300} - 43,33^2 = 14,18$ et $\sigma_3(X) = \sqrt{14,18} = 3,77$.

2.3 RELATIONS ENTRE LES MOYENNES MARGINALES ET CONDITIONNELLES

Les moyennes conditionnelles et marginales sont liées par la relation suivante : la moyenne des moyennes conditionnelles de X est égale à la moyenne marginale de X.

Cette propriété est à relier à la notion d'espérance conditionnelle en probabilité.

Soit $\bar{\bar{x}}$ la moyenne des moyennes conditionnelles. La démonstration suivante montre que $\bar{\bar{x}}$ est égale à la moyenne marginale de X, c'est-à-dire $\bar{x}$:

$$\begin{aligned} \bar{\bar{x}} &= \frac{1}{n_{++}} \sum_{j=1}^q n_{+j} \bar{x}_j = \frac{1}{n_{++}} \sum_{j=1}^q n_{+j} \left(\frac{1}{n_{+j}} \sum_{i=1}^p n_{ij} x_i \right) = \frac{1}{n_{++}} \sum_{j=1}^q \sum_{i=1}^p n_{ij} x_i \\ &= \frac{1}{n_{++}} \sum_{i=1}^p x_i \left(\sum_{j=1}^q n_{ij} \right) = \frac{1}{n_{++}} \sum_{i=1}^p x_i n_{i+} = \bar{x} \end{aligned}$$

Exemple 5.7

Vérification de la relation entre moyennes marginales et conditionnelles

Reprenons les données de l'exemple 5.5.

Extrayons les distributions conditionnelles de X sachant Y = y₁ (voir figure 5.3).

Figure 5.3

Distribution conditionnelle de X sachant Y = y₁.

	A	B	C	D
1	x_i	n_{i1}	$n_{i1}x_i$	$n_{i1}x_i^2$
2	20	300	6000	120000
3	35	70	2 450	85 750
4	45	20	900	40 500
5	Somme	390	9 350	246 250

$$\text{D'où } \bar{x}_1 = \frac{1}{n_{+j}} \sum_{i=1}^3 n_{ij} x_i = \frac{9\,350}{390} = 23,97.$$

En faisant de même pour les distributions conditionnelles de X sachant $Y = y_2$ et de X sachant $Y = y_3$, on obtient :

$$\bar{x}_2 = \frac{1}{n_{+j}} \sum_{i=1}^3 n_{ij} x_i = \frac{9\,950}{310} = 32,10 ; \quad \bar{x}_3 = \frac{1}{n_{+j}} \sum_{i=1}^3 n_{ij} x_i = \frac{13\,000}{300} = 43,33.$$

La distribution des moyennes conditionnelles de X est proposée figure 5.4.

Figure 5.4

Distribution des moyennes conditionnelles de X.

	A	B	C	D
1	j	$\bar{x}_j$	n_{+j}	$n_{+j} \bar{x}_j$
2	1	23,97	390	9 350
3	2	32,10	310	9 950
4	3	43,33	300	13 000
5	Somme		1 000	32 300

$$\text{D'où la moyenne des moyennes conditionnelles de X : } \bar{\bar{x}} = \frac{1}{n_{++}} \sum_{j=1}^3 n_{+j} \bar{x}_j = \frac{32\,300}{1000} = 32,3.$$

Or, $\bar{x} = 32,3$ (voir exemple 5.5). Donc, la relation entre $\bar{x}$ et $\bar{\bar{x}}$ est vérifiée.

2.4 LA COVARIANCE

Nous avons vu que la variabilité des caractères quantitatifs à une variable autour de leur moyenne pouvait être mesurée par la variance. Dans le cas des séries doubles, nous disposons d'un indicateur comparable, appelé covariance, qui permet de mesurer les fluctuations simultanées de chaque variable par rapport à sa moyenne. Il est important de noter que, contrairement à la variance (moyenne de carrés) qui est toujours positive ou nulle, la covariance peut être de signe quelconque.

Définition

La **covariance** : Soit X et Y deux caractères quantitatifs. La covariance du couple (X ; Y) est

$$\text{définie par : } \text{Cov}(X; Y) = \frac{1}{n_{++}} \sum_{j=1}^q \sum_{i=1}^p n_{ij} (x_i - \bar{x})(y_j - \bar{y}) = \sum_{j=1}^q \sum_{i=1}^p f_{ij} (x_i - \bar{x})(y_j - \bar{y}).$$

Graphiquement, cette définition revient à prendre un nouveau repère d'origine G $(\bar{x}; \bar{y})$, le point moyen, et à diviser le plan en quatre quadrants, respectivement définis


par : $Q_1 \left\{ \begin{matrix} x \geq \bar{x} \\ y \geq \bar{y} \end{matrix} \right.$, $Q_2 \left\{ \begin{matrix} x \leq \bar{x} \\ y \geq \bar{y} \end{matrix} \right.$, $Q_3 \left\{ \begin{matrix} x \leq \bar{x} \\ y \leq \bar{y} \end{matrix} \right.$ et $Q_4 \left\{ \begin{matrix} x \geq \bar{x} \\ y \leq \bar{y} \end{matrix} \right.$. On notera que les quadrants Q_1 et

Q_3 sont associés, car les points M $(x_i; y_j)$ du nuage situé dans le domaine $Q_1 \cup Q_3$ sont caractérisés par $(x_i - \bar{x})(y_j - \bar{y}) \geq 0$, les quantités $(x_i - \bar{x})$ et $(y_j - \bar{y})$ étant de même signe. De même, $Q_2 \cup Q_4$ est caractérisé par $(x_i - \bar{x})(y_j - \bar{y}) \leq 0$. Ainsi, le signe de la covariance nous indiquera si les points du nuage sont majoritairement dans $Q_1 \cup Q_3$ ou

dans $Q_2 \cup Q_4$ (voir figure 5.5) ; nous reviendrons sur cette remarque dans l'étude de la régression (voir chapitre 6).

Figure 5.5

Nuages de points $(x_i ; y_i)$.



Comme pour la variance, la covariance admet une formule développée. Cette formule est issue du théorème de Koenig.

Définition

Formule développée de la covariance :
$$\text{Cov}(X; Y) = \frac{1}{n_{++}} \sum_{j=1}^q \sum_{i=1}^p n_{ij} x_i y_j - \bar{x} \times \bar{y}.$$

Par cette formule, la covariance est la « moyenne des produits moins le produit des moyennes ».

De même que la variance, la covariance possède des propriétés très importantes :

Propriétés

$\text{Cov}(X ; Y) = \text{Cov}(Y ; X)$: la covariance est symétrique.

$\text{Cov}(X ; X) = \text{Var}(X)$: la covariance est obtenue en « dédoublant » la formule de la variance.

$\text{Cov}(aX ; a'Y) = aa' \text{Cov}(X ; Y)$: multiplier chacune des séries par un réel multiplie la covariance par le produit de ces nombres.

$\text{Cov}(X+b ; Y) = \text{Cov}(X ; Y)$: ajouter une constante ne change pas la covariance.

Le signe de la covariance possède une signification (voir figure 5.5) :

- Une covariance positive indique que les caractères X et Y varient globalement dans le même sens, une hausse de l'un étant associée à une hausse de l'autre, ou encore une baisse de l'un étant associée à une baisse de l'autre.
- Une covariance négative indique que les caractères X et Y varient globalement en sens contraires, une hausse de l'un étant associée à une baisse de l'autre.

Exemple 5.8

Calcul de covariance dans le cas de données exhaustives

Reprenons les données de l'exemple 5.1 et calculons la covariance avec la formule développée. On rappelle que $n = 3$; $\bar{x} = 9\,721$; $\bar{y} = 7\,176$. On calcule chacun des $x_i y_i$ et on en fait la somme (voir figure 5.6).

Figure 5.6

Calcul des $x_i y_i$.

	A	B	C	D
1	Académie	x	y	$x_i y_i$
2	Paris	14 150	11 271	159 484 650
3	Créteil	7 759	5 150	39 958 850
4	Versailles	7 254	5 107	37 046 178
5	Somme	29 163	21 528	236 489 678

Source : ministère de l'Éducation nationale, 2006

D'où $\sum_{j=1}^q \sum_{i=1}^p n_{ij} x_i y_j = 236\,489\,678$. D'où, en utilisant la formule développée :

$$\text{Cov}(X; Y) = \frac{1}{3} \sum_{j=1}^3 \sum_{i=1}^3 n_{ij} x_i y_j - \bar{x} \times \bar{y} = \frac{1}{3} 236\,489\,678 - 9\,721 \times 7\,176,$$

soit $\text{Cov}(X; Y) = 9\,071\,996,76$. Le nombre de licenciés en 2005 varie dans le même sens que le nombre de licenciés poursuivant leurs études à l'université en 2006.

Dans le chapitre suivant nous affinerons l'étude de la relation entre deux caractères et nous verrons le rôle de la covariance dans le calcul du coefficient de corrélation linéaire.

3 Étude des liaisons entre deux variables

La notion de liaison entre deux variables est un premier stade incontournable vers une éventuelle imputation causale qu'il est fondamental de mettre en évidence dans de nombreux domaines, notamment en épidémiologie, justice, économie, sociologie, etc. Dans le cas particulier de deux caractères quantitatifs, le degré d'association peut varier entre deux extrêmes : d'un côté la liaison fonctionnelle et de l'autre l'indépendance.

3.1 LIAISON FONCTIONNELLE ET INDÉPENDANCE

Prenons l'exemple du jeu de la roulette. La roulette comporte 37 numéros (numérotés de 0 à 36), 18 rouges, 18 noirs, le zéro étant vert. À la suite de 100 parties, notons respectivement X et Y le nombre de numéros rouges et de numéros noirs sortis.

Si le zéro n'existait pas, nous aurions entre X et Y la relation fonctionnelle $X + Y = 100$; avec la présence d'une case verte, nous avons un degré de liaison très fort entre X et Y, le zéro ayant une probabilité faible de sortie.

Définition

Un caractère X est **lié fonctionnellement** au caractère Y si à chaque modalité de Y correspond une seule modalité de X.

La liaison fonctionnelle n'est pas symétrique : si X est fonctionnellement lié à Y, cela n'implique pas que Y le soit fonctionnellement à X.

Exemple 5.9

Liaison fonctionnelle et absence de symétrie

Supposons que, suite à l'introduction sur le marché d'un nouveau produit, une enquête de satisfaction sur un échantillon de 200 consommateurs des deux sexes ait donné les résultats suivants, avec X le sexe et Y la satisfaction :

X \ Y	Insatisfait	Ni satisfait, ni insatisfait	Satisfait	Somme
Masculin (M)	20	70	0	90
Féminin (F)	0	0	110	110
Somme	20	70	110	200

X est fonctionnellement lié à Y, car pour chaque modalité de Y résulte une seule modalité de X ; ainsi, un consommateur satisfait est nécessairement un homme. Par contre, Y n'est pas fonctionnellement lié à X, car à la modalité Masculin de X correspondent deux modalités possibles de Y : Insatisfait ou Ni satisfait, ni insatisfait.

La liaison fonctionnelle n'est pas symétrique.

Reprenons l'exemple du jeu de la roulette et imaginons une roulette comportant un très grand nombre de cases vertes : les caractères X et Y seraient à peu près indépendants.

Définition

Deux variables statistiques X et Y sont **indépendantes** si les distributions conditionnelles de X sachant Y sont identiques, ce qui équivaut à : $f_{(X=x_i/Y=y_j)} = f_{i+}$, quels que soient les indices i et j (i entier compris entre 1 et p et j entre 1 et q). Dans le cas où X et Y sont indépendants, les distributions conditionnelles de X selon Y sont identiques à la distribution marginale de X.

Le concept d'indépendance étant symétrique, l'indépendance se traduit également par la relation $f_{(Y=y_j/X=x_i)} = f_{+j}$.

Cette notion est similaire à la notion d'indépendance probabiliste :

$$P_B(A) = P(A \cap B) / P(B).$$

Exemple 5.10

Étude de l'indépendance

Reprenons les données de l'exemple 5.2. Leur étude a mené au calcul des fréquences conditionnelles de X sachant Y, rappelées dans le tableau suivant :

X \ Y	y₁ = O	y₂ = N
x ₁ = M	f _{i=1/j=1} = 0,6729	f _{i=1/j=2} = 0,7206
x ₂ = F	f _{i=2/j=1} = 0,3271	f _{i=2/j=2} = 0,2794
f_{+j}	1	1

De même, les fréquences marginales de X avaient été calculées : f₁₊ = 0,70 et f₂₊ = 0,30, soit 70 % d'hommes et 30 % de femmes.

Parmi les individus ayant répondu oui, il y a 67,29 % d'hommes et 32,71 % de femmes, ce qui est différent des proportions d'hommes et de femmes dans l'échantillon étudié, qui sont respectivement de 70 % et de 30 %. Ces résultats montrent que les caractères X et Y ne sont pas indépendants, car les distributions conditionnelles de X selon Y ne sont pas égales à la distribution marginale de X (voir définition de l'indépendance, ci-avant) : la réponse d'un individu n'est pas indépendante de son sexe.

Conclusion

Ce chapitre est un chapitre clef à double titre : tout d'abord il a introduit les outils de base des séries bivariées, qui seront nécessaires pour aborder, au chapitre 6, la régression ; ensuite il a introduit le concept fondamental d'indépendance. Cette notion a été l'occasion de présenter une initiation aux tests statistiques, qui constituent un aspect fondamental de l'inférence statistique.

Le lecteur doit maîtriser les concepts d'effectifs (et de fréquences) conditionnels et marginaux, ainsi que les éléments ayant trait aux tableaux de contingence : utilisation rigoureuse des indices, notion de degré de liberté. La covariance, son calcul sous les deux formes et l'interprétation de son signe doivent être bien connus.

Enfin, le lecteur doit s'attacher à une rédaction rigoureuse et systématique dans l'élaboration d'un test d'hypothèse. Les calculs intervenant dans le test du khi-deux exigent une démarche, des notations et une présentation claires. Par ailleurs, indépendamment de l'utilisation du tableur, il est fondamental d'être familiarisé avec la table de la distribution du khi-deux.

La régression

L'analyse linéaire de la régression a un double objectif : d'une part expliciter le modèle décrivant les relations entre une variable privilégiée, appelée variable expliquée (dépendante ou endogène), et une variable appelée variable explicative (indépendante ou exogène), et d'autre part effectuer des prévisions de la variable expliquée en fonction de la variable explicative.

Dans ce cas, l'ajustement analytique sera effectué à l'aide de la méthode des moindres carrés, que nous devons à Carl Friedrich Gauss (1777-1855) et Adrien-Marie Legendre (1752-1833), et qui nous permettra de déterminer les équations des droites de régression. Nous envisagerons également des liaisons plus complexes (exponentielles), en utilisant une représentation graphique (nuage de points) comme outil de conjecture.

Enfin, une fois les calculs menés sur un échantillon, il importera d'utiliser un test statistique permettant de valider ou de rejeter l'existence d'un lien linéaire entre les variables sur la population.

1 Les fondements de la régression

1.1 TERMINOLOGIE

Il importe avant tout de préciser certains termes : régression, corrélation, indépendance.

Nous avons vu, au chapitre 5, un exemple (voir exemple 5.9) de liaison fonctionnelle non symétrique. De même, les notions de régression et de corrélation ne donnent pas un rôle symétrique aux deux variables. Quand deux variables ne sont pas liées par une relation fonctionnelle pure, on devra se contenter de regarder comment, en moyenne, se font les variations respectives de ces variables. On associera ainsi à chaque modalité x_i de X la moyenne conditionnelle $\bar{y}_i$.

Définitions

Liaison fonctionnelle : On dit que la variable Y est fonctionnellement liée à X si à chaque modalité de X correspond une seule modalité de Y.

De même X est liée fonctionnellement à Y si à chaque modalité de Y correspond une seule modalité de X.

Si X est liée fonctionnellement à Y et Y est liée fonctionnellement à X, on parle de liaison fonctionnelle réciproque.

Courbes de régression : On appelle courbe de régression de Y selon x la courbe représentative des moyennes conditionnelles $\bar{y}_i$ en fonction des valeurs x_i de X. On remarquera que si X est une variable discrète on aura en fait une suite de points appelée nuage de points.

On définit de même la courbe de régression de X selon y.

Point moyen : On appelle point moyen du nuage le point G de coordonnées respectives $\bar{x}$ et $\bar{y}$.

Dans le cas particulier où les variables X et Y sont indépendantes, les distributions conditionnelles sont identiques entre elles (et confondues avec la distribution marginale correspondante). On a donc dans ce cas des moyennes conditionnelles constantes et donc des droites de régression parallèles aux axes et d'équations respectives $x = \bar{x}$ et $y = \bar{y}$. On notera que la réciproque est fautive : des droites de régression parallèles aux axes n'impliquent pas l'indépendance.

Étudier la corrélation d'une variable Y avec une variable X consiste à étudier la dépendance des moyennes conditionnelles de Y en fonction des valeurs de X . L'étude de la corrélation de Y avec X se base sur la courbe de régression de Y selon X et sur la mesure de l'intensité de cette corrélation.

Définition

Corrélation : Une variable Y est dite corrélée avec X si la courbe de régression de Y selon X n'est pas une droite parallèle à l'axe des abscisses.

On notera que :

- l'absence de corrélation n'est en général pas symétrique : X peut être corrélée avec Y sans que Y soit corrélée avec X ;
- si X et Y sont des variables indépendantes, X n'est pas corrélée à Y et Y n'est pas corrélée à X , mais l'indépendance n'est qu'un cas particulier d'absence de corrélation.

1.2 LES DIFFÉRENTS AJUSTEMENTS STATISTIQUES

Nous supposons que nous disposons d'un tableau simple donnant les modalités $(x_i ; y_i)$, pour i variant de 1 à n , d'un couple de variables quantitatives, pour un échantillon aléatoire, de taille n , prélevé dans la population. Avant toute étude, la série sera représentée par un diagramme de corrélation (ou de dispersion) afin d'apprécier le type d'ajustement adapté. Ce diagramme, appelé nuage de points, est obtenu en plaçant dans un repère les n points de coordonnées $(x_i ; y_i)$. La forme de ce nuage permettra de mettre au jour une éventuelle corrélation entre les variables. Réaliser un ajustement consiste à rechercher la meilleure relation possible entre les variables, donc à rechercher la courbe la plus « proche » de l'ensemble des points du nuage.

Les liaisons fonctionnelles (rigides)

Ce type de liaison, que l'on rencontre par exemple dans de nombreuses lois physiques, a été défini au chapitre 5 et constitue un modèle déterministe. Une liaison fonctionnelle peut être linéaire ou non, conformément aux cas décrits dans les exemples 6.1 et 6.2.

Exemple 6.1

Liaison fonctionnelle linéaire


Le tableau suivant donne, pour un échantillon de 10 garçons de 18 ans prélevé dans la population d'un lycée, les tailles respectives (exprimées en centimètres), x_i et y_p , à 2 ans et à 20 ans :

X	Y
82	164,1
82,4	164,9
83	166,1
84	168,1
86	172,1
87	174,1
88,6	177,3

X	Y
90	180,1
92,5	185,1
93	186,1

Figure 6.1

Exemple de relation fonctionnelle linéaire.



Sur la figure 6.1, l'alignement des points met en évidence une relation fonctionnelle linéaire entre les deux variables. On peut vérifier que, sur cet échantillon, y est une fonction affine¹ de x : $y_i = 2x_i + 0,1$.

On notera que, si le modèle linéaire est fondamental, on ne peut négliger les autres ajustements : ajustement logarithmique, exponentiel, polynomial, puissance. Le lecteur pourra se familiariser avec ces différents modèles grâce à l'exemple 6.2 ci-après. Il pourra utiliser, dans l'assistant graphique d'Excel, le sous-menu « Ajouter une courbe de tendance », ou se reporter au corrigé de l'exercice 1, figures 6.6 et 6.7.

Exemple 6.2

Liaison fonctionnelle non linéaire

L'exemple qui suit est une illustration de « l'étonnante loi de Benford » qui modélise la fréquence d'apparition du premier chiffre significatif de données statistiques (voir J.-P. Delahaye).

On considère un échantillon de 300 pays. On note X le premier chiffre du nombre représentant la population de chaque pays (les modalités étant notées x_i) et Y la variable dont les modalités notées y_i sont les fréquences des x_i :


X	Y
1	0,3010
2	0,1760
3	0,1249
4	0,09691
5	0,0792

1. Une fonction affine est une fonction définie de $\mathbb{R}$ dans $\mathbb{R}$ par $f(x) = ax + b$, dont la représentation graphique est une droite non verticale.

X	Y
6	0,0669
7	0,0580
8	0,0511
9	0,0458

Figure 6.2

Exemple de relation fonctionnelle non linéaire.



Les points de la figure 6.2 ne sont pas alignés, mais le nuage montre l'existence d'une liaison non linéaire. Y et X sont liées par la relation logarithme décimal : $Y = \log(1 + 1/x)$.

L'absence de liaison

Dans le cas d'un nuage de points diffus et répartis au hasard, il est possible de conclure à l'absence de liaison entre les variables X et Y, comme le montre l'exemple 6.3.


Exemple 6.3

Absence de liaison

Soit un échantillon de 31 étudiants ayant obtenu les notes X et Y dans deux matières. Le diagramme de dispersion correspondant est proposé figure 6.3.

Figure 6.3

Absence de corrélation.



Ce nuage de points sans liens apparents permet de conjecturer une absence de liaison entre les variables. Il n'y a pas corrélation entre X et Y.

Les liaisons statistiques

Dans de nombreuses sciences, nous cherchons à mettre en évidence une liaison entre deux variables X et Y . Le plus souvent, la liaison cherchée n'est pas purement fonctionnelle et l'on parle de liaison stochastique pour exprimer qu'à une valeur de X correspond un ensemble de valeurs possibles de Y , distribuées suivant une loi de probabilité. Dans ce cas, les points ne sont plus alignés, mais le nuage de points a une forme allongée qui évoque une droite.

Cette droite constitue une liaison statistique entre les deux variables ; il nous reste à préciser en quoi cette droite est « la plus proche du nuage » et à exposer la méthode permettant de déterminer une équation de cette droite : la méthode des moindres carrés ordinaires (MCO).

2 L'ajustement linéaire

En cherchant à mettre en évidence une fonction f qui représente la liaison statistique entre deux variables X et Y , on se trouve face au problème général de l'interpolation. La détermination analytique de f aurait *a priori* comme seule contrainte de vérifier $y_i = f(x_i)$, avec Y la variable expliquée et en faisant abstraction des erreurs dues à l'échantillon.

Dans le cas où le nuage de points a une forme allongée, on présume un ajustement linéaire. La fonction cherchée est une fonction affine. Le but est de trouver la meilleure droite qui résume le nuage de points, ce qui nous amène à résoudre un problème d'interpolation linéaire. Pour cela, nous utilisons une propriété importante de la moyenne arithmétique : la moyenne arithmétique d'une série est le nombre le plus proche de cette série au sens des moindres carrés.

2.1 DROITES DE RÉGRESSION PAR LA MÉTHODE MCO

La loi normale ou de Laplace-Gauss est encore appelée loi des erreurs ou des écarts, car c'est ainsi qu'elle a été introduite. Le principe de la méthode des moindres carrés ordinaires (MCO) consiste à s'intéresser à la série statistique des erreurs ou résidus (e_i).

On notera que l'on peut émettre des hypothèses sur le choix de la variable expliquée, mais que le statisticien doit également mener les calculs dans le cas où X est la variable expliquée. Il appartiendra au spécialiste concerné – économiste, médecin, etc. – de décider éventuellement d'écarter un des cas sur la base d'une analyse propre à sa spécialité.

Définitions

On appelle **droite de régression de Y selon x** , notée $D_{Y/X}$, déterminée par la méthode des moindres carrés, la droite d'équation $y = ax + b$, pour laquelle la somme des carrés des résidus est minimale.

On note $\hat{y}_i = ax_i + b$ la valeur de y_i estimée par la droite de régression de Y selon x .

De même, la **droite de régression de X selon y** , notée $D_{X/Y}$ est la droite d'équation $x = a'y + b'$ avec $\hat{x}_i = a'y_i + b'$.

Notons que, graphiquement, la somme des carrés des résidus représente la somme des carrés des écarts entre les points du nuage et la droite, écarts calculés parallèlement à l'axe des ordonnées dans le cas de la droite de régression de Y selon x.

À partir du modèle linéaire construit, il est possible d'effectuer des prévisions. Dans le cas d'une liaison linéaire avérée, une fois déterminée la droite de régression de Y selon x, on peut l'utiliser pour estimer la valeur de y associée à une valeur de x appartenant à l'étendue des valeurs de x retenues dans l'échantillon. Dans ce cas, il n'y a pas de raison statistique de supposer que le modèle linéaire puisse se prolonger au-delà de l'intervalle étudié. Si l'on effectue des prévisions en dehors de l'intervalle défini par les valeurs extrêmes de x, on peut obtenir des valeurs aberrantes.

On pourra sortir de cet intervalle, notamment dans les séries chronologiques, à condition d'avoir des informations sur la stabilité de la liaison linéaire.

Détermination des droites de régression

Remarque préalable : nous cherchons à déterminer les paramètres a et b traduisant une éventuelle liaison linéaire du type $Y = aX + b$ (dans le cas de la droite de régression de Y selon x) entre les variables X et Y ; pour cela, nous devons déterminer les paramètres a et b de la droite qui « s'éloigne » le moins du nuage de points constitué par un échantillon de taille n de la population. En conséquence, nous allons déterminer des estimateurs de a et b, c'est-à-dire des fonctions des n observations de l'échantillon, notées $\hat{a}$ et $\hat{b}$, qui permettent d'obtenir les meilleures estimations possibles des paramètres a et b.

Dans les calculs, nous garderons les notations a et b de la statistique descriptive.

Posons : $\hat{y} = ax + b$, a désignant le coefficient directeur de la droite $D_{Y/X}$ et b l'ordonnée à l'origine (on notera que certains auteurs prennent la notation : $\hat{y} = a + bx$). Nous devons déterminer les estimateurs de a et b qui minimisent

$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - ax_i - b)^2 = S(a; b).$$

S est une fonction de deux variables et les mathématiques nous enseignent que les conditions nécessaires du premier ordre pour avoir un extremum (minimum ou maximum) sont :

$$\begin{cases} \frac{\partial S}{\partial a} = 0 \\ \frac{\partial S}{\partial b} = 0 \end{cases}, \text{ c'est-à-dire la nullité des dérivées partielles premières.}$$

$$\frac{\partial S}{\partial a} = -2 \sum_{i=1}^n x_i (y_i - ax_i - b) \text{ et } \frac{\partial S}{\partial b} = -2 \sum_{i=1}^n (y_i - ax_i - b) ; \text{ on doit résoudre le système :}$$

$$\begin{cases} \sum_{i=1}^n x_i (y_i - ax_i - b) = 0 \\ \sum_{i=1}^n (y_i - ax_i - b) = 0 \end{cases} . \text{ En utilisant les relations } \sum_{i=1}^n x_i = n\bar{x} \text{ et } \sum_{i=1}^n y_i = n\bar{y}, \text{ on obtient :}$$

$$\begin{cases} \sum_{i=1}^n (x_i y_i - a x_i^2 - b x_i) = 0 \\ n\bar{y} - a n\bar{x} - nb = 0 \end{cases}. \text{ La deuxième équation du système s'écrit } b = \bar{y} - a\bar{x}, \text{ ce qui}$$

permet de remplacer b par sa valeur dans la première équation du système, ce qui

$$\text{donne : } \sum_{i=1}^n x_i y_i - a \sum_{i=1}^n x_i^2 - (\bar{y} - a\bar{x}) \sum_{i=1}^n x_i = 0 \text{ soit } \sum_{i=1}^n x_i y_i - a \sum_{i=1}^n x_i^2 - n\bar{x}(\bar{y} - a\bar{x}) = 0 \text{ soit}$$

$$a \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}, \text{ qui donne : } a = \frac{n\text{Cov}(X;Y)}{nV(X)} = \frac{\text{Cov}(X;Y)}{V(X)}.$$

Nous admettons que ces valeurs correspondent bien à un minimum.

Les calculs sont similaires pour la droite de régression de X selon y ; on retiendra donc les résultats suivants pour les estimateurs de a et b, notés $\hat{a}$ et $\hat{b}$:

$$D_{Y/X} : y = ax + b, \text{ avec } \begin{cases} \hat{a} = \frac{\text{Cov}(X;Y)}{V(X)} \\ \hat{b} = \bar{y} - \hat{a}\bar{x} \end{cases} \text{ et } D_{X/Y} : x = a'y + b', \text{ avec } \begin{cases} \hat{a}' = \frac{\text{Cov}(X;Y)}{V(Y)} \\ \hat{b}' = \bar{x} - \hat{a}'\bar{y} \end{cases}.$$

Ces deux droites se coupent au point moyen G. La droite de régression de X selon y peut être mise sous forme affine : $y = (1/a')x - (b'/a')$, de façon à faire apparaître son coefficient directeur : $1/a'$.

Exemple 6.4

Calculs de droites de régression

Le tableau suivant donne les indices du pouvoir d'achat (base 100 en 1951) du salaire minimum net, noté X, et du salaire moyen, noté Y, pour les salariés français des secteurs privé et semi-public.

Année	X	Y
1994	293	329
1995	296	336
1996	296	334,35
1997	302,15	337,33
1998	311,45	340,34
1999	313,93	345,76
2000	315,47	347,46
2001	321,99	349,17
2002	326,41	352,25
2003	330,57	350,87

Source : Insee, 2006

Pour calculer les coefficients des droites de régression, il est nécessaire de calculer les moyennes, les écarts-types et la covariance de X et Y. La figure 6.4 propose les calculs intermédiaires nécessaires, réalisés sous Excel.

Figure 6.4

Calculs préliminaires
sous Excel.

	A	B	C	D	E	F
1	Année	x_i	y_i	x_i^2	y_i^2	$x_i y_i$
2	1994	293,00	329,00	85 849,00	108 241,00	96 397,00
3	1995	296,00	336,00	87 616,00	112 896,00	98 448,00
4	1996	296,00	334,35	87 616,00	111 789,92	97 964,55
5	1997	302,15	337,33	91 294,62	113 791,53	98 837,69
6	1998	311,45	340,34	97 001,10	115 831,32	99 719,62
7	1999	313,93	345,76	98 552,04	119 549,96	101 307,68
8	2000	315,47	347,46	99 521,32	120 728,45	101 805,78
9	2001	321,99	349,17	103 677,56	121 919,69	102 306,81
10	2002	326,41	352,25	106 543,49	124 080,06	103 209,25
11	2003	330,57	350,87	109 276,52	123 109,76	102 804,91
12	Somme	3 106,97	3 422,53	966 947,66	1 171 937,70	1 002 801,29

$$\text{De là, } \bar{x} = \frac{1}{10} \sum_{i=1}^{10} x_i = \frac{3\,106,97}{11} = 310,7, \quad \bar{y} = \frac{1}{10} \sum_{i=1}^{10} y_i = \frac{3\,422,53}{10} = 342,25,$$

$$V(x) = \frac{1}{10} \sum_{i=1}^{10} x_i^2 - \bar{x}^2 = \frac{966\,944,70}{10} - (310,7)^2 = 162,09 \text{ et}$$

$$V(y) = \frac{1}{10} \sum_{i=1}^{10} y_i^2 - \bar{y}^2 = \frac{1\,171\,938,41}{10} - (342,25)^2 = 56,66.$$

$$\text{Cov}(x; y) = \frac{1}{10} \sum_{i=1}^{10} x_i y_i - \bar{x} \times \bar{y} = \frac{1064\,294,54}{10} - 310,7 \times 342,25 = 92,57.$$

On dispose donc de tous les éléments pour calculer des estimations des paramètres a, b, a' et b' :

$$\hat{a} = \text{Cov}(x; y) / V(x) = 92,57 / 162,09 = 0,5711 \text{ et } \hat{b} = \bar{y} - \hat{a}\bar{x} = 342,25 - 0,5711 \times 310,7 = 164,80.$$

$$\hat{a}' = \text{Cov}(x; y) / V(y) = 92,57 / 56,66 = 1,6340 \text{ et } \hat{b}' = \bar{x} - \hat{a}'\bar{y} = 310,7 - 1,6340 \times 342,25 = -248,54.$$

$$\text{On obtient les droites de régression : } \begin{cases} D_{Y/X} : y = 0,5711x + 164,80 \\ D_{X/Y} : x = 1,6340y - 248,54 \end{cases}.$$

On peut vérifier que ces deux droites sont sécantes au point moyen G.

Si nous validons provisoirement l'existence d'un lien linéaire entre X et Y, les valeurs de x varient dans l'intervalle [293 ; 330,57] et cet intervalle est en toute rigueur l'intervalle de validité du modèle. Si nous relevons une valeur de l'indice du pouvoir d'achat du salaire minimum $x = 305$, on peut faire une prévision pour y : $\hat{y} = 0,5711x + 164,80$ soit $\hat{y} = 0,5711 \times 305 + 164,80 = 338,99$.

De même, sachant que l'indice du pouvoir d'achat du salaire minimum en 2005 est $x = 341,90$, il est possible d'utiliser $D_{Y/X}$ pour faire une « prévision » de l'indice du pouvoir d'achat du salaire moyen en 2005, soit $\hat{y} = 0,5711 \times 341,9 + 164,8 = 360,06$. Cependant, la valeur $x = 341,90$ est hors de l'intervalle de construction du modèle défini par [293 ; 330,57]. C'est pourquoi nous n'avons pas d'information sur la fiabilité de cette prévision (en réalité, la vraie valeur est 351,56).

Les droites de régression peuvent également être construites dans le cas de données contenues dans un tableau de contingence. La détermination de a , b , a' et b' , coefficients des droites de Y selon x et de X selon y , nécessite les calculs de moyennes, de variances et de la covariance, qui peuvent être effectués à partir des valeurs du tableau de contingence (voir exercice 3).

Deux annexes, proposées en fin de chapitre, sont consacrées à la réalisation d'une droite de régression sous Excel (annexe 6.1), ou tout autre tableur équivalent, et avec une calculatrice graphique, Texas Instrument (annexe 6.2), ou toute autre calculatrice approchante.

2.2 LE COEFFICIENT DE CORRÉLATION LINÉAIRE

L'intensité de la corrélation est d'autant plus grande que les points du nuage sont plus concentrés au voisinage de la courbe de régression. On voit ainsi l'importance de s'intéresser à la dispersion et à la composition de la variance de Y dans l'étude de la corrélation.

Décomposition de la variance

La droite de régression $D_{Y/X}$ donne pour estimation de y : $\hat{y} = ax + b$.

En remplaçant b par sa valeur $b = \bar{y} - a\bar{x}$, $\hat{y} = ax + \bar{y} - a\bar{x}$ soit $\hat{y} - \bar{y} = a(x - \bar{x})$.

Calculons la variance des deux membres : $V(\hat{y} - \bar{y}) = V(a(x - \bar{x}))$, soit, en utilisant les propriétés de la variance : $V(\hat{y}) = a^2 V(x - \bar{x}) = a^2 V(x)$. Or, $a = \frac{\text{Cov}(x; y)}{V(x)}$, donc

$$V(\hat{y}) = \left(\frac{\text{Cov}(x; y)}{V(x)} \right)^2 V(x) = \frac{\text{Cov}(x; y)^2}{V(x)}.$$

Reprenons la somme des carrés des erreurs et calculons sa valeur minimale S_m , en remplaçant a et b par leurs valeurs :

$$S_m = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \bar{y} - a(x_i - \bar{x}))^2 = \sum_{i=1}^n (y_i - \bar{y})^2 + a^2 \sum_{i=1}^n (x_i - \bar{x})^2 - 2a \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})$$

soit, en divisant par n et en remplaçant a par sa valeur :

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = V(y) + \frac{\text{Cov}(x; y)^2}{V(x)} - 2 \frac{\text{Cov}(x; y)^2}{V(x)} = V(y) - \frac{\text{Cov}(x; y)^2}{V(x)} = V(y) - V(\hat{y})$$

$$\text{soit } V(y) = V(\hat{y}) + \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

La variance totale de Y , $V(y)$, est la somme de deux termes :

- $V(\hat{y})$, appelée variance expliquée par la droite de régression. Elle mesure la dispersion de y quand on résume le nuage à la droite de régression $D_{Y/X}$ et représente la dispersion le long de la droite de régression ;

- $\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$, qui est la moyenne des carrés des écarts (comptés parallèlement à l'axe des ordonnées) entre les points du nuage et la droite $D_{Y/X}$. Elle représente la variance résiduelle, notée $V_r(y)$.

Ainsi, **Variance totale** = **Variance expliquée** + **Variance résiduelle**, soit $V(y) = V(\hat{y}) + V_r(y)$.

Si la variance résiduelle est nulle, cela signifie que tous les points du nuage sont sur la droite de régression, et la variance est entièrement expliquée par la droite de régression.

On pourra utiliser les notations suivantes :

somme des carrés totaux : $SCT = \sum_{i=1}^n (y_i - \bar{y})^2$, somme des carrés expliqués :

$SCE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ et somme des carrés résiduels : $SCR = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ avec :

$SCT = SCE + SCR$.

Exemple 6.5

L'équation de l'analyse de la variance

Reprenons les données de l'exemple 6.4 et calculons les variances expliquée et résiduelle à l'aide d'Excel (voir figure 6.5).

Figure 6.5

Calcul des variances expliquée et résiduelle.

	A	B	C	D	E	F
1	Année	x_i	y_i	$\hat{y}$	$(y_i - \hat{y}_i)^2$	$(\hat{y}_i - \bar{y})^2$
2	1994	293,00	329,00	332,15	9,90	102,10
3	1995	296,00	336,00	333,86	4,57	70,36
4	1996	296,00	334,35	333,86	0,24	70,36
5	1997	302,15	337,33	337,37	0,00	23,81
6	1998	311,45	340,34	342,68	5,48	0,19
7	1999	313,93	345,76	344,10	2,76	3,42
8	2000	315,47	347,46	344,98	6,15	7,45
9	2001	321,99	349,17	348,70	0,22	41,61
10	2002	326,41	352,25	351,23	1,05	80,59
11	2003	330,57	350,87	353,60	7,45	128,85
12	Somme	3 106,97	3 422,53	3 422,53	37,81	528,74

On a : $SCE = 528,74$, $SCR = 37,81$ et $SCT = SCE + SCR = 566,55$. La variance résiduelle

est $V_r(y) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{37,81}{10} = 3,78$ et la variance expliquée par la droite de régression

est $V(\hat{y}) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \frac{528,74}{10} = 52,87$, notée aussi V_e . La variance totale de y est

$V(y) = 56,65$.

De là, l'équation de l'analyse de variance $V(y) = V(\hat{y}) + V_r(y)$ est vérifiée : $56,65 = 52,87 + 3,78$.

On constate avec cet exemple que la variance expliquée représente $52,87 / 56,65$, soit environ 93,32 % de la variance totale. Autrement dit : 93,32 % de la variation de Y est expliquée par la variation de X . Ce résultat est un bon indicateur de la qualité de la liaison linéaire ; nous y reviendrons à la section suivante.

Les coefficients de corrélation linéaire et de détermination

La variance expliquée est donnée par la relation $V(\hat{y}) = \frac{\text{Cov}(x; y)^2}{V(x)}$. Nous avons vu dans

l'exemple 6.5 qu'il est intéressant d'apprécier la part de la variance expliquée dans la variance totale. Nous allons donc transformer cette relation pour exprimer la variance expliquée en fonction de la variance totale. En multipliant numérateur et dénominateur de la relation précédente par $V(y)$, il vient $V(\hat{y}) = \frac{\text{Cov}(x; y)^2}{V(x)V(y)} V(y)$, soit

$\frac{V(\hat{y})}{V(y)} = \frac{\text{Cov}(x; y)^2}{V(x)V(y)}$. Ce rapport représente la part de variance expliquée sur la variance totale. Il est appelé coefficient de détermination (noté R^2) et amène les définitions ci-après.

Définition

On appelle **coefficient de corrélation linéaire**, noté r , entre les variables quantitatives X et Y , le nombre sans dimension, défini par : $r = \frac{\text{Cov}(x; y)}{\sigma(x)\sigma(y)}$.

r est symétrique par rapport à X et Y et est de même signe que la covariance : un coefficient positif (respectivement négatif) indique que X et Y varient dans le même sens (respectivement en sens contraire).

La relation entre les variances expliquée et totale s'écrit : $V(\hat{y}) = r^2 V(y)$, et l'équation de l'analyse de variance $V(y) = V(\hat{y}) + V_r(y)$ s'écrit alors : $V(y) = r^2 V(y) + V_r(y)$ soit $V_r(y) = (1 - r^2) V(y)$. Les variances étant positives, cette relation prouve que la quantité $1 - r^2$ reste positive ou nulle, c'est-à-dire que : $-1 \leq r \leq 1$.

Les coefficients directeurs des droites de régression sont respectivement a ($D_{Y/X}$) et $1/a'$ ($D_{X/Y}$) et nous pouvons écrire : $a = \frac{\text{Cov}(x; y)}{V(x)} = r \frac{\sigma(y)}{\sigma(x)}$ et $\frac{1}{a'} = \frac{1}{r} \times \frac{\sigma(y)}{\sigma(x)}$. On vérifie que a , a' et r sont de même signe. Par ailleurs, les droites de régression sont confondues si et seulement si : $a = 1/a'$ soit $r^2 = 1$ soit $r = -1$ ou $r = 1$.

Définition

On appelle **coefficient de détermination**, noté R^2 , le quotient entre la variance expliquée et la variance totale. On a : $R^2 = \text{SCE} / \text{SCT}$.

Propriété

Le coefficient de détermination est le carré du coefficient de corrélation.

Quelques considérations importantes :

- Cet indice est compris entre 0 et 1 et mesure la qualité de l'ajustement de la droite de régression aux points du nuage.
- R^2 mesure la part de la variance expliquée par les droites de régression, $V(\hat{y})$, rapportée à la variance totale, $V(y)$; ce coefficient de détermination s'exprime souvent en pourcentage.

- Plus R^2 est grand (proche de 1), plus la variance résiduelle (inexpliquée par la droite de régression) est petite ; cela explique qu'il est souhaitable d'avoir un coefficient de détermination proche de 1 si l'on désire utiliser la régression pour faire des prévisions.
- On vérifie par un calcul immédiat : $R^2 = \frac{Cov^2(x; y)}{V(x)V(y)} = \frac{V(\hat{y})}{V(y)} = \frac{V(\hat{x})}{V(x)}$, ou encore $R^2 = r^2 = a \times a'$. Cette dernière expression permet de retrouver r , en étant vigilant sur son signe : r est du signe commun aux deux nombres a et a' et on aura donc : $r = \sqrt{a \times a'}$ si a et a' sont positifs et $r = -\sqrt{a \times a'}$ si a et a' sont négatifs.
- En valeur absolue, le coefficient de corrélation est supérieur ou égal au coefficient de détermination. En effet, $-1 \leq r \leq 1$, et $0 \leq r^2 \leq 1$; or, la racine carrée d'un nombre compris entre 0 et 1 est supérieure ou égale à ce nombre. On en déduit que $|r| \geq R^2$.

Exemple 6.6

Calculs des coefficients de corrélation linéaire et de détermination

Prolongeons l'exemple 6.5 en conclusion duquel nous avons montré que la variance expliquée représente 52,87 / 56,65 soit environ 93,32 % de la variance totale, autrement dit que 93,32 % de la variation de Y est expliquée par la variation de X . Ce résultat est retrouvé en calculant $R^2 = \frac{V(\hat{y})}{V(y)} = \frac{52,87}{56,65} = 93,32 \%$.

Ou encore, à partir des résultats de l'exemple 6.4 :

$$R^2 = \frac{Cov^2(x; y)}{V(x) \times V(y)} = \frac{92,57^2}{162,09 \times 56,65} = 93,32 \%, \text{ ou } R^2 = a \times a' = 0,5711 \times 1,6340 = 0,9332.$$

Puisque la corrélation est positive, a et a' sont positifs et $r = \sqrt{a \times a'} = \sqrt{0,9332} = 0,9660$.

Interprétation du coefficient de corrélation

Le coefficient de corrélation est toujours compris entre -1 et 1 et *a priori* :

- si r est proche de 1 (droites de régression très voisines), la corrélation linéaire entre X et Y est positive et forte ;
- si r est proche de -1 (droites de régression très voisines), la corrélation linéaire entre X et Y est négative et forte ;
- si r est voisin de 0 (droites de régression proches de l'orthogonalité), la corrélation linéaire entre X et Y est faible.

Quelques mises en garde dans l'interprétation du coefficient de corrélation linéaire doivent être effectuées :

- La corrélation n'est pas une relation de causalité. On a pu mettre en évidence une forte corrélation entre la vente de glaces et la vente de crèmes à bronzer, entre l'augmentation des salaires des enseignants et la consommation d'alcool. Il appartient au spécialiste du domaine d'étude de s'interroger sur un éventuel lien de causalité, à partir de connaissances extérieures au domaine statistique.

- L'absence de corrélation linéaire ne signifie pas l'absence de lien. Il peut exister une liaison fonctionnelle autre que linéaire (parabolique, exponentielle...).
- Le nombre d'observations utilisées pour déterminer le coefficient de corrélation est très important. Le coefficient de corrélation est généralement calculé à partir d'un échantillon de taille n extrait de la population totale et ne donne qu'une estimation ponctuelle du coefficient de corrélation inconnu, noté ρ , de la population totale.

3 Ajustements et absence de linéarité

3.1 AJUSTEMENT LINÉAIRE PAR CHANGEMENT DE VARIABLE

Dans certains cas où, clairement, les points ne sont pas alignés, le graphique représentant le nuage de points permet de rejeter directement l'hypothèse d'une corrélation linéaire. Il est alors possible de revenir à la théorie de la corrélation linéaire en utilisant un changement de variable, afin de déterminer la relation fonctionnelle qui lie les deux variables.

Par exemple :

- Soit la relation non linéaire $y = a \ln x + b$. En posant $X = \ln(x)$, cette relation non linéaire est équivalente à la relation linéaire $y = a X + b$.
- Soit la relation non linéaire $y = a \exp x + b$. En posant $X = \exp x$, cette relation non linéaire est équivalente à la relation linéaire $y = a X + b$.
- Soit la relation non linéaire $y = b \times a^x$. En prenant le logarithme de cette expression, $\ln y = \ln(b \times a^x) = \ln b + x \ln a$, soit avec $B = \ln b$; $A = \ln a$; $Y = \ln y$, cette relation non linéaire est équivalente à la relation linéaire $Y = Ax + B$.
- Soit la relation non linéaire $y = b \times x^a$. En prenant le logarithme de cette expression, $\ln y = \ln(b \times x^a) = \ln b + a \ln x$, soit avec $B = \ln b$; $Y = \ln y$; $X = \ln x$, cette relation non linéaire est équivalente à la relation linéaire $Y = a X + B$.
- Modèle logistique : ce modèle est défini par $y = k/(1 + a \exp(-b x))$ et peut être ramené à un modèle linéaire. Ce modèle a été introduit par Pierre François Verhulst (1804-1849), élève de Quetelet, lors de l'étude de l'évolution d'une population qui croît exponentiellement au début puis se stabilise, freinée par un phénomène de surpopulation (saturation), pour tendre vers sa capacité maximale. Ce modèle est utilisé notamment pour le traitement des séries chronologiques (voir chapitre 7).

BIBLIOGRAPHIE

Ce cours est essentiellement tiré de:

Statistique descriptive
Applications avec Excel et la calculatrice

Étienne Bressoud

Université Paris 8 Vincennes-Saint-Denis

Jean-Claude Kahané

Université Paris 8 Vincennes-Saint-Denis

Directeur de collection : Roland Gillet

Université Paris 1 Panthéon-Sorbonne

Collection Synthex
Synthèse de cours-exercices corrigés